University of Chinese Academy of Sciences

硕士学位论文

大模型强化学习中自适应 Rollout 采样策略研究

作者姓名：闫嘉序

指导教师：李伟 副研究员 中国科学院计算技术研究所

学位类别：工学硕士

学科专业：计算机科学与技术

培养单位：中国科学院计算技术研究所

2026 年 6 月

Research on Adaptive Rollout Sampling Strategy in LLM Reinforcement Learning

A thesis submitted to

University of Chinese Academy of Sciences

in partial fulfillment of the requirement

for the degree of

Master of Engineering

in Computer Science and Technology

By

Yan Jiaxu

Supervisor: Associate Professor Li Wei

Institute of Computing Technology, Chinese Academy of Sciences

June, 2026

中国科学院大学
学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明或致谢。

作者签名：

日　　期：

中国科学院大学
学位论文授权使用声明

本人完全了解并同意遵守中国科学院有关保存和使用学位论文的规定，即中国科学院有权保留送交学位论文的副本，允许该论文被查阅，可以按照学术研究公开原则和保护知识产权的原则公布该论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：　　导师签名：

日　　期：　　日　　期：

摘 要

大型语言模型（LLM）的强化学习微调在提升模型推理能力方面展现出巨大潜力。然而，当前主流的 GRPO 算法采用固定采样策略，导致简单问题产生冗余样本，困难问题因采样不足而面临”信号崩溃”——即组内奖励全同时策略梯度退化为零。这一问题在高难度数学推理任务中尤为突出，严重制约了训练效率与最终性能。

本文提出了一种基于历史指导的几何自适应采样框架（History-Guided Geometric Adaptive Sampling, H-GAS），通过三个协同组件系统性地解决上述问题:（1）**几何倍增采样**以指数递增的步长动态扩展采样规模，具有竞争最优的搜索效率;（2）**基于历史难度的热启动**利用问题难度的时序连续性，跳过已知的低效搜索区间，从合理的初始采样数出发;（3）**能量守恒的动态升温**在采样规模扩大时同步提升采样温度，确保新增样本的探索有效性。

在以 Qwen2.5-Math-1.5B 为主实验模型的评测中，H-GAS 在 MATH500、AMC23、AIME24、AIME25、OlympiadBench 五个数学推理基准上全面超越 GRPO 基线，平均提升 3.6 个百分点。其中，在 MATH500 基准测试上，H-GAS 相比 GRPO-n8 基线提升 3.6 个百分点（70.6% → 74.2%）；在竞赛级基准 AIME24 上从 13.8% 提升至 17.3%（相对提升 25.4%）。在 Qwen2.5-Math-7B、Qwen3-1.7B-Base 和 Llama-3.2-3B 上的多模型实验证实了方法的跨架构泛化性。消融实验表明三个组件形成了”预算分配—历史复用—多样性增强”的完整协同闭环，收敛速度相比 GRPO 基线加快 1.5–2 倍。

关键词：大语言模型，强化学习，几何倍增采样，历史先验热启动，动态温度调度，自适应采样

Abstract

Reinforcement Learning (RL) fine-tuning has demonstrated significant potential in enhancing the reasoning capabilities of Large Language Models (LLMs). However, the widely adopted GRPO algorithm employs a fixed sampling strategy that leads to redundant samples for easy problems and "signal collapse" for difficult ones—where all samples in a group receive identical rewards, causing the advantage function and policy gradient to degenerate to zero. This issue is particularly pronounced in challenging mathematical reasoning tasks.

This thesis proposes History-Guided Geometric Adaptive Sampling (H-GAS), a framework that systematically addresses signal collapse through three synergistic components: (1) **Geometric Progressive Sampling** dynamically expands sampling budgets via exponential scaling, achieving competitive optimality without prior knowledge of problem difficulty; (2) **History-Aware Warm Start** leverages temporal continuity in problem difficulty across training rounds to bypass known inefficient search intervals; and (3) **Entropy-Conservative Dynamic Temperature** synchronously increases sampling temperature as the sampling scale grows, ensuring effective exploration of new samples.

Experiments on Qwen2.5-Math-1.5B demonstrate that H-GAS consistently outperforms the GRPO baseline across five mathematical reasoning benchmarks (MATH500, AMC23, AIME24, AIME25, OlympiadBench), achieving an average improvement of 3.6 percentage points, with AIME24 improving from 13.8% to 17.3% (a 25.4% relative gain). Multi-model experiments on Qwen2.5-Math-7B, Qwen3-1.7B-Base and Llama-3.2-3B confirm cross-architecture generalizability. Ablation studies reveal that the three components form a complete synergistic loop of "budget allocation–history reuse–diversity enhancement", accelerating convergence by 1.5–2× compared to the GRPO baseline.

Keywords: Large Language Model, Reinforcement Learning, Geometric Progressive

Sampling, History Prior Warm Start, Dynamic Temperature Scheduling, Adaptive Sampling

目 录

第 1 章 绪论 ····· 1
1.1 研究背景与意义 ····· 1
1.1.1 大型语言模型的崛起与挑战 ····· 1
1.1.2 强化学习在 LLM 中的关键作用 ····· 2
1.1.3 Rollout 阶段：核心瓶颈与研究意义 ····· 3
1.2 国内外研究现状 ····· 4
1.3 本文主要研究内容与贡献 ····· 6
1.4 本文组织结构 ····· 7
第 2 章 相关工作 ····· 8
2.1 大语言模型强化学习基础 ····· 8
2.1.1 策略梯度与 REINFORCE 算法 ····· 8
2.1.2 近端策略优化（PPO） ····· 9
2.1.3 组相对策略优化（GRPO） ····· 9
2.1.4 REINFORCE++ 与 DAPO ····· 11
2.2 自适应采样与 Rollout 优化 ····· 11
2.2.1 RAFT：奖励排序微调 ····· 12
2.2.2 Reinforce-Ada：非线性目标下的自适应采样 ····· 12
2.2.3 AR3PO：自适应 Rollout 与响应复用 ····· 13
2.2.4 CoPRIS：部分 Rollout 与重要性采样 ····· 14
2.2.5 其他相关工作 ····· 14
2.3 课程学习与难度感知训练 ····· 15
2.4 相关方法综合对比 ····· 17
2.5 本章小结 ····· 17
第 3 章 H-GAS：历史指导的几何自适应采样方法 ····· 19
3.1 问题定义与符号说明 ····· 19
3.2 固定采样策略的局限性分析 ····· 22
3.2.1 信号崩溃问题的数学本质 ····· 22
3.2.2 采样效率的理论分析 ····· 22
3.2.3 问题难度的时序连续性 ····· 23
3.3 H-GAS 框架总体设计 ····· 24
3.4 几何倍增采样 ····· 25

3.4.1 与线性增长的对比 ····· 25
3.4.2 与 Reinforce-Ada 权重机制的本质区别 ····· 27
3.4.3 退出条件与样本利用 ····· 28
3.5 基于历史难度的热启动 ····· 28
3.5.1 历史表的定义与维护 ····· 28
3.5.2 热启动公式 ····· 29
3.5.3 与在线估计方法的冷启动对比 ····· 29
3.5.4 存储开销分析 ····· 30
3.6 能量守恒的动态升温 ····· 30
3.6.1 动机：采样多样性的衰减 ····· 30
3.6.2 动态温度调度公式 ····· 31
3.6.3 与 Entropy Bonus 的区别 ····· 31
3.7 算法总流程 ····· 32
3.7.1 三组件协同机制 ····· 32
3.7.2 H-GAS 单提示词采样流程 ····· 33
3.7.3 H-GAS 集成到 GRPO 训练 ····· 33
3.7.4 计算复杂度分析 ····· 33
3.7.5 与标准 GRPO 的对比总结 ····· 36
3.8 本章小结 ····· 36
第 4 章 实验与分析 ····· 37
4.1 实验设置 ····· 37
4.1.1 模型与数据集 ····· 37
4.1.2 评测基准 ····· 37
4.1.3 训练配置 ····· 38
4.1.4 对比方法 ····· 39
4.2 主要实验结果 ····· 39
4.2.1 Qwen2.5-Math-1.5B 上的性能对比 ····· 39
4.2.2 多模型泛化性验证 ····· 41
4.3 收敛速度分析 ····· 43
4.4 消融实验 ····· 45
4.4.1 组件贡献分析 ····· 46
4.4.2 超参数敏感性分析 ····· 47
4.5 采样动态分析 ····· 48
4.6 奖励-熵权衡分析 ····· 49
4.7 定性分析与典型案例 ····· 50

4.8 典型案例分析 ····· 51
4.8.1 案例一：简单题目（通过率 $p \approx 0.85$） ····· 51
4.8.2 案例二：中等难度题目（通过率 $p \approx 0.45$） ····· 52
4.8.3 案例三：困难题目（通过率 $p \approx 0.06$） ····· 52
4.9 训练效率分析 ····· 53
4.10 本章小结 ····· 53
第 5 章 总结与展望 ····· 55
5.1 全文总结 ····· 55
5.2 主要贡献 ····· 56
5.3 局限性分析 ····· 56
5.4 未来研究方向 ····· 58
附录 A 附录：超参数设置与实现细节 ····· 60
A.1 实验超参数汇总 ····· 60
A.2 历史难度表实现 ····· 60
A.3 计算环境 ····· 61
参考文献 ····· 62
作者简历及攻读学位期间发表的学术论文与研究成果 ····· 65

图形列表

4.1 MATH500 上的训练曲线对比。H-GAS 在训练初期即展现出明显的加速效果，约在 300 步收敛至最终性能水平，而 GRPO-n8 在 500 步后仍有缓慢提升。 ····· 43

4.2 收敛速度对比：以总推理调用次数为横轴的准确率变化。在相同的计算预算下，H-GAS 能够达到更高的准确率，体现了其采样效率的优势。 ····· 44

4.3 消融实验柱状图：各组件在五个基准上的渐进贡献。从 GRPO-n8 出发，依次叠加几何采样（GS）、历史热启动（HS）和动态升温（Full H-GAS），性能逐步提升。 ····· 45

4.4 H-GAS 在不同难度问题上的采样次数分布。简单问题集中在 4 次采样，中等问题分布在 8–16 次，困难问题呈现几何增长特性，累计采样可达 $K_{\max} = 32$ 次。 ····· 48

表格列表

2.1 相关方法综合对比。”是”表示该方法在相应维度具有完整支持，”部分”表示仅具有有限支持。 ····· 17

3.1 本章主要符号说明 ····· 21
3.2 动态温度调度示例（$T_{\text{base}} = 0.7$，$\alpha = 0.1$，$K_{\text{base}} = 4$） ····· 32
3.3 H-GAS-GRPO 与标准 GRPO 的对比 ····· 36

4.1 训练超参数配置 ····· 38
4.2 Qwen2.5-Math-1.5B 为主实验模型的性能对比（准确率%）† ····· 40
4.3 多模型泛化性验证：各模型上 GRPO 与 H-GAS 的性能对比（准确率%） ····· 42
4.4 消融实验：H-GAS 各组件的渐进贡献分析（准确率%） ····· 46
4.5 训练效率对比（Qwen2.5-Math-1.5B，8 块 A100 40GB GPU） ····· 53

A.1 H-GAS 完整超参数列表 ····· 60

符号列表

字符

符号	含义	说明
θ	当前策略网络参数	策略参数
θ_{old}	旧策略网络参数（更新前的基线）	策略参数
K	当前轮次对提示词 x 的采样数量	采样参数
K_{base}	初始采样基数（默认值 4）	采样参数
$K_{\max}$	最大采样上限（默认值 32）	采样参数
$p(x)$	提示词 x 的历史通过率（难度代理）	难度指标
$f_t(x)$	提示词 x 在第 t 轮的连续失败次数	难度指标
$\mathcal{H}$	历史难度表，存储各提示词的历史通过率	历史表
T	当前采样温度	温度参数
T_{base}	基础采样温度（默认值 0.7）	温度参数
α	温度调节系数（默认值 0.1）	温度参数
r_i	第 i 个输出样本的奖励值	奖励
A_i	第 i 个输出样本的归一化优势估计	优势函数
π_θ	参数为 θ 的语言模型策略	策略
$\mathcal{D}$	训练数据集	数据集
$\mathcal{X}$	提示词（prompt）空间	输入空间

算子

符号	含义
$\mathbb{E}[\cdot]$	期望算子
$\min(\cdot,\cdot)$	取最小值
$\log(\cdot)$	自然对数
$\log_2(\cdot)$	以 2 为底的对数
$\text{clip}(\cdot)$	裁剪函数

缩写

LLM　Large Language Model，大语言模型

RL　Reinforcement Learning，强化学习

RLHF　Reinforcement Learning from Human Feedback，基于人类反馈的强化学习

GRPO　Group Relative Policy Optimization，组相对策略优化

PPO　Proximal Policy Optimization，近端策略优化

H-GAS　History-Guided Geometric Adaptive Sampling，历史引导的几何自适应采样

CoT　Chain-of-Thought，思维链

SFT　Supervised Fine-Tuning，监督微调

KL　Kullback-Leibler（散度）

第 1 章　绪论

1.1　研究背景与意义

1.1.1　大型语言模型的崛起与挑战

近年来，大型语言模型（Large Language Models, LLMs）的快速发展重塑了人工智能的研究方向与应用版图。这一进程始于 2017 年 Vaswani 等人提出的 Transformer 架构 [1]，该架构通过自注意力机制（Self-Attention）实现了对序列数据的高效并行建模，取代了此前主导自然语言处理领域的循环神经网络（Recurrent Neural Networks）范式。在 Transformer 架构的基础上，预训练语言模型的研究迎来了爆发式增长。2019 年，Devlin 等人提出的 BERT [2] 通过双向掩码语言建模（Masked Language Modeling）在多项自然语言理解任务上取得了突破性成果，开创了 “预训练–微调”（Pre-train and Fine-tune）的研究范式。与此同时，以 GPT 系列为代表的自回归语言模型沿着 “规模扩展”（Scaling Up） [3] 的路径持续演进。Brown 等人提出的 GPT-3 [4] 将模型参数规模扩展至 1750 亿，首次展现了大型语言模型的少样本学习（Few-shot Learning）和上下文学习（In-context Learning）等涌现能力。随后，OpenAI 发布的 GPT-4 [5] 进一步将多模态理解与复杂推理能力推向新的高度，在法律考试、医学资格认证等专业领域的表现甚至超越了多数人类考生。

在这一技术浪潮中，以 DeepSeek 系列为代表的开源大语言模型也取得了令人瞩目的进展。DeepSeek-R1 [6] 通过大规模强化学习训练，使模型自发涌现出自我反思和长程推理能力，在数学竞赛、代码生成等复杂任务上达到了与闭源模型相当的水平。这些成果表明，大型语言模型的能力边界仍在不断拓展。

然而，当前大型语言模型的训练范式正在经历显著变化。传统的 “预训练 + 监督微调” 两阶段方法逐渐演变为 “预训练 + 后训练”（Pre-training + Post-training）的新范式，其中后训练阶段包含监督微调（Supervised Fine-Tuning, SFT）和强化学习（Reinforcement Learning, RL）等多个环节。预训练阶段通过海量无标注文本数据赋予模型基本的语言理解和生成能力，但这种能力是 “原始” 的，模型的输出可能包含事实错误、有害内容或与人类意图不一致的回复。后训练阶段的核心目标是弥补这一差距：通过监督微调使模型学会遵循指令，通过强化学习使模

型在与人类价值观对齐的同时提升其在复杂推理任务上的能力。在这一过程中，强化学习作为后训练阶段的关键技术手段，其重要性日益凸显。

1.1.2 强化学习在 LLM 中的关键作用

强化学习通过构建“智能体–环境”交互范式，使大型语言模型能够超越监督学习的局限性，在复杂决策和推理场景中实现持续优化。其核心优势在于：模型可以通过试错学习来优化那些难以用确定性规则描述的目标函数，例如回复的有用性、安全性和推理的正确性。

基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）是将强化学习引入大型语言模型训练的开创性范式 [7]。Ouyang 等人在 InstructGPT 的工作中首次系统性地将 RLHF 应用于大规模语言模型的对齐训练：首先收集人类标注的偏好数据训练一个奖励模型（Reward Model），然后利用近端策略优化（Proximal Policy Optimization, PPO）算法 [8] 根据奖励模型的反馈信号优化语言模型的策略。这一范式在 ChatGPT 等产品中取得了巨大成功，显著提升了模型输出的质量和安全性。然而，RLHF 面临奖励模型训练成本高、人类偏好标注主观性强、奖励信号可能被模型“攻击”（Reward Hacking）等问题。

针对推理能力提升这一更具挑战性的目标，成果导向型强化学习（Outcome-based RL / Reinforcement Learning with Verifiable Rewards, RLVR）提供了一种更为直接有效的途径。与基于偏好的 RLHF 不同，RLVR 利用客观可验证的正确性判定（如数学答案是否正确、代码是否通过测试用例）作为奖励信号，避免了奖励模型引入的噪声和偏差。DeepSeek-R1 [6] 的成功充分验证了 RLVR 范式的巨大潜力：通过在纯强化学习环境下进行大规模训练，模型自发地涌现出自我验证、回溯修正和思维链推理（Chain-of-Thought Reasoning）等高级认知能力。这一发现表明，强化学习不仅可以用于行为对齐，更能作为释放模型深层推理潜力的关键手段。

回顾近年来 LLM 与强化学习融合的发展脉络，可以清晰地看到一条从”对齐”到”推理”、从”大模型”到”小模型”的演进路线。2022 年，Ouyang 等人提出 InstructGPT [7]，首次将 RLHF 系统性地应用于大型语言模型的对齐训练，奠定了基于人类反馈的强化学习范式。2024 年，DeepSeekMath 团队提出 GRPO [9]，摒弃了价值函数网络，通过组内相对奖励归一化大幅降低了训练成本，成功将强化学习从对齐任务扩展到数学推理领域。2025 年初，DeepSeek-R1 [6] 进一步证

明，纯强化学习训练可以激发模型自发涌现自我反思和长程推理等高级认知能力，而这种涌现效应在小参数量模型中同样可以观察到。同期，Qwen3 [10] 系列模型的发布表明，1.7B 参数规模的基础模型经过适当的强化学习训练，即可在数学推理任务上展现出令人瞩目的性能提升潜力。这些进展共同揭示了一个关键事实：当前制约 LLM 强化学习训练效率的核心瓶颈已从算法设计层面转移至 Rollout 采样效率层面——如何在有限的计算预算下生成高质量的训练信号，成为释放强化学习全部潜力的关键所在。

从方法论的角度看，当前主流的 LLM 强化学习算法均建立在策略梯度（Policy Gradient）理论 [11, 12] 的基础之上。经典的 REINFORCE 算法 [12] 通过蒙特卡洛采样估计策略梯度，为后续工作奠定了理论基础。PPO [8] 通过引入裁剪目标函数（Clipped Objective）和信赖域约束，在保证训练稳定性的同时提高了采样效率。近年来，GRPO [9] 摒弃了价值函数网络，通过组内相对奖励归一化来估计优势函数，大幅降低了显存开销和系统复杂度，成为当前大规模 LLM 强化学习训练的主流选择。本文的研究正是在 GRPO 等策略梯度算法的框架下展开，旨在优化这些算法中最关键也最耗时的 Rollout 环节。

1.1.3　Rollout 阶段：核心瓶颈与研究意义

大型语言模型的强化学习微调通常包含三个核心环节：Rollout（策略采样）、Make Experience（经验构造）和 Training（策略更新）。Rollout 阶段指模型根据当前策略，针对给定的输入提示词（Prompt）自回归地生成完整的响应序列；Make Experience 阶段对生成的响应进行奖励评估并计算优势函数；Training 阶段则利用构造的经验数据通过策略梯度方法更新模型参数。

在这三个环节中，Rollout 阶段是整个训练流程的主要计算瓶颈。由于大型语言模型的自回归生成本质——每个 token 的生成都依赖于前序所有 token 的计算结果，生成过程无法像前向传播和反向传播那样实现高度并行化。根据已有研究和工程实践的报告 [13]，Rollout 阶段通常占据 RL 微调总训练时间的 50% 以上。当模型参数规模增大或生成序列长度增加时，这一比例还会进一步上升。因此，对 Rollout 阶段的效率优化是降低 LLM 强化学习训练总成本的最有效切入点。

除了计算效率之外，Rollout 的质量同样至关重要，因为它直接决定了学习信号的有效性。在基于组相对策略优化（GRPO） [9] 的训练范式中，算法对同

一提示词生成一组（Group）响应，并通过组内奖励的归一化来估计每个样本的优势值。当组内所有样本的奖励完全一致时——即所有响应全部正确或全部错误——归一化后的优势值将趋近于零，策略梯度退化为零梯度，模型无法从这些样本中获得任何有意义的学习信号 [14]。这种现象被称为“信号崩溃”（Signal Collapse）。在实际训练中，信号崩溃问题普遍存在：对于模型已经掌握的简单问题，多次采样几乎必然全部正确；对于远超模型当前能力的极难问题，多次采样也几乎必然全部错误。只有那些难度适中的问题——模型有一定概率答对也有一定概率答错的问题——才能在组内产生有效的奖励方差，从而为策略更新提供信息量丰富的梯度信号 [14, 16]。

我们在 Qwen2.5-Math-1.5B 上的预实验统计表明，在标准 GRPO 训练中（组大小 $G = 8$，训练集为 OpenR1-Math-220k，共 50 步暖身），约 19% 的训练批次中存在全对或全错的情况，与 AR3PO [21] 和 DAPO [16] 等工作的观测结果一致。从更长的训练尺度来看，约有 65% 的提示词在整个训练过程中至少出现过一次全对或全错的情况（与 Reinforce-Ada [20] 报告的信号退化比例吻合），导致策略梯度退化为零；即使将采样数增大至 $G = 16$，仍有超过 50% 的提示词无法产生有效学习信号。传统方法通常对所有问题采用固定的采样次数（即统一的 Group Size），这种“一刀切”的策略在面对不同难度的问题时显然是低效的。对于简单问题，少量采样即可确认模型已掌握，过多采样只是浪费计算资源；对于困难问题，固定的采样次数可能不足以发现任何正确解，导致整组样本提供零学习信号。因此，如何根据问题难度和模型当前能力动态调整采样策略，在有限的计算预算下最大化有效学习信号的产出率，是提升 LLM 强化学习训练效率的关键科学问题。这正是本文研究的核心出发点。

1.2 国内外研究现状

围绕大型语言模型强化学习微调及 Rollout 效率优化，国内外学术界已从多个方向展开了深入探索。

在**强化学习微调算法**方面，研究者沿着从复杂到轻量的路径不断迭代。以 PPO [8] 为代表的经典方法通过裁剪目标函数保证策略更新的稳定性，在 InstructGPT [7] 等工作中取得了显著成效，但同时维护 Actor、Critic、Reference、Reward 四个网络的高资源需求限制了其向更大规模模型的扩展。为此，GRPO [9] 摒弃

价值函数网络，利用组内相对奖励作为基线估计优势函数，大幅降低了显存开销；REINFORCE++ [15]、DAPO [16] 等后续工作则在训练稳定性和信号有效性上做出了进一步改进。总体而言，当前算法的轻量化趋势为大规模强化学习训练提供了可行的基座，但对 Rollout 采样策略本身的优化仍然有限。

在 **Rollout 效率优化**方面，现有工作大致沿五条路线展开：基于拒绝采样的”先生成后筛选” 范式（如 RAFT [17]、ReMax [18]），侧重于提高训练数据质量但无法回收已消耗的推理资源；事后数据筛选方法（如 DAPO 的动态采样 [16]、PODS [19]），在 Rollout 完成后过滤零方差样本组，本质上属于被动过滤策略；自适应采样方法（如 Reinforce-Ada [20]、AR3PO [21]），开始从” 主动调整” 的视角重新审视采样分配问题；基于课程学习的问题选择策略（如 CDAS [22]、SEC [23]），在” 训练哪些问题” 的维度上进行了深入探索但未涉及单题采样次数的优化；以及部分 Rollout 方法（如 CoPRIS [24]），从 token 生成维度降低单次采样成本。这些工作分别从不同侧面推进了 Rollout 效率的提升，但在以下三个层面仍存在共同的不足。

现有方案的核心局限性可以归纳为三点。其一，大部分方法采取” 先生成、后过滤” 的被动策略，无效计算开销已经产生后才进行筛选，未能在采样过程中根据中间结果即时调整后续行为。其二，” 问题选择” 与” 采样分配” 相互割裂——课程学习方法可以选出难度适中的训练题目，但对被选中题目仍施加固定的采样次数，忽略了不同通过率的问题在最优采样数上的显著差异。其三，历史信息利用不足——模型在多轮迭代中对同一训练集的采样结果蕴含丰富的难度与能力信息，但现有方法大多将各轮视为独立过程，未能利用这种时序连续性来指导当前轮次的采样决策。

在自适应采样方向上，Reinforce-Ada [20] 通过在线梯度方差估计动态分配采样预算，但其冷启动阶段的估计方差较大，导致训练初期采样策略不稳定。H-GAS 通过引入历史难度先验规避了这一问题，在训练全程均能保持稳定、高效的采样分配。

本文正是从上述三个局限性出发，提出了融合主动调整、动态采样分配和历史信息利用的自适应 Rollout 策略——H-GAS，旨在从根本上解决固定采样次数带来的资源浪费与学习信号不足问题。本文第二章将对上述各方向的代表性方法进行系统梳理和深入分析。

1.3 本文主要研究内容与贡献

本文围绕大型语言模型强化学习微调中 Rollout 阶段的效率与学习信号优化问题，开展了以下三个方面的研究工作。

第一，样本组方差与学习信号有效性的理论分析。本文深入研究了基于 GRPO 算法的策略梯度估计中，样本组内奖励方差与梯度信号有效性之间的定量关系。通过理论推导证明，只有当样本组内同时包含正确和错误的响应时，策略梯度的估计才是有效的。全对或全错的样本组导致优势函数退化为零，对策略更新无任何贡献。这一分析为后续动态采样策略的设计提供了理论基础。

第二，基于几何倍增的自适应采样策略设计。本文提出了 H-GAS 框架中的核心采样机制——几何倍增采样（Geometric Doubling Sampling）。该机制以最小采样数为起点，根据已有采样结果动态判断是否需要继续增加采样次数：如果当前样本组已经包含有效的正负信号，则立即停止采样以节省计算资源；如果信号崩溃（全对或全错），则将采样次数按几何级数倍增，直至发现有效信号或达到预设的最大采样数上限。这种策略在对数级别的尝试次数内逼近每个问题的最优采样数，实现了采样效率与信号质量的有效平衡。

第三，历史信息驱动的热启动与动态升温机制。本文发现问题难度在连续训练轮次间具有显著的时序连续性（Temporal Momentum），即上一轮中困难的问题在当前轮次中大概率仍然困难。基于这一发现，H-GAS 引入了历史热启动（History Warm-Start）机制，利用上一轮的采样结果为当前轮次的初始采样数提供先验估计，避免了每轮从最小值重新开始探索的冗余计算。此外，本文还设计了基于能量守恒的动态升温策略（Energy-Conservative Dynamic Warm-Up），在训练初期节约的采样预算可以“存储”起来，在训练后期当模型能力提升、需要攻克更难问题时“释放”使用，实现了训练全程的采样预算优化配置。

本文的主要贡献如下：

- 提出几何倍增采样机制，基于历史通过率动态分配采样预算，从理论上证明其相比固定采样的信息增益优势；
- 设计基于历史先验的热启动策略，利用历史难度估计避免冷启动问题，使自适应采样在训练初期即可发挥作用；
- 引入能量守恒的动态温度调度，在保持总采样预算不变的前提下，动态平衡探索与利用，提升训练稳定性。

1.4　本文组织结构

本文共分为五章，各章内容安排如下：

第一章为绪论。介绍本文的研究背景与意义，概述大型语言模型和强化学习微调技术的发展现状，分析 Rollout 阶段面临的核心挑战，综述国内外相关研究工作及其局限性，并阐述本文的研究内容和主要贡献。

第二章为相关工作与技术基础。系统介绍本文研究所涉及的核心概念和基础方法，包括大型语言模型的预训练与后训练范式、强化学习基础理论、策略梯度方法以及 GRPO 算法的详细原理，为后续章节的方法设计和理论分析奠定基础。

第三章为 H-GAS 方法。详细阐述本文提出的历史指导几何自适应采样框架，包括几何倍增采样机制、基于历史难度的热启动策略、能量守恒的动态升温方法三个核心组件，并给出完整的算法描述和理论分析。

第四章为实验与分析。介绍实验设置与评估方案，展示 H-GAS 在多个基础模型和标准基准上的性能表现，通过消融实验验证各组件的有效性，并通过采样动态分析和案例研究深入剖析方法的工作机制。

第五章为总结与展望。总结本文的研究工作和主要发现，分析现有方法的局限性，并对未来的研究方向进行展望。

本章小结

本章围绕 LLM 强化学习微调中 Rollout 阶段的效率瓶颈展开论述，揭示了固定采样策略导致信号崩溃的核心矛盾——简单问题采样冗余而困难问题信号缺失。通过梳理现有方法在被动过滤与主动调整、问题选择与采样分配、历史信息利用三个层面的不足，本章明确了研究的出发点和主要贡献。下一章将回顾相关工作与技术基础。

第 2 章　相关工作

本章系统回顾与本文研究密切相关的已有工作。首先介绍大语言模型强化学习的基础算法演进，包括策略梯度、PPO、GRPO 等核心方法；随后梳理近期在自适应采样与 Rollout 优化方面的研究进展；最后讨论课程学习与难度感知训练的相关方法，并在本章小结中指出本文方法的独特定位。

2.1　大语言模型强化学习基础

2.1.1　策略梯度与 REINFORCE 算法

策略梯度方法是强化学习中一类重要的优化范式，其核心思想是直接对策略函数 π_θ 进行参数化，并通过估计目标函数 $J(\theta)$ 关于参数 θ 的梯度来更新策略。Sutton 等人 [11] 在其经典工作中证明了策略梯度定理，为这一类方法奠定了理论基础。策略梯度定理表明，目标函数的梯度可以表示为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta}\left[\nabla_\theta \log \pi_\theta(a|s) \cdot Q^{\pi_\theta}(s,a)\right] \tag{2.1}$$

其中 $Q^{\pi_\theta}(s,a)$ 为动作价值函数，$\pi_\theta(a|s)$ 为在状态 s 下选择动作 a 的概率。

REINFORCE 算法 [12] 是策略梯度方法最早且最简洁的实现之一。Williams 于 1992 年提出该算法，其核心思想是利用蒙特卡洛采样对策略梯度进行无偏估计。具体而言，REINFORCE 通过完整的轨迹回报 G_t 来替代动作价值函数 $Q^{\pi_\theta}(s,a)$，从而避免了对价值函数的显式估计。然而，REINFORCE 的一个主要缺陷在于其梯度估计的方差较高，这是因为蒙特卡洛回报本身具有较大的随机性。

为缓解高方差问题，研究者引入了基线函数（Baseline）$b(s)$，将梯度估计修正为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta}\left[\nabla_\theta \log \pi_\theta(a|s) \cdot (G_t - b(s))\right] \tag{2.2}$$

只要基线函数不依赖于动作 a，该估计仍然是无偏的，同时通过减去基线可以显著降低方差。常见的基线选择包括状态价值函数 $V^{\pi_\theta}(s)$ 及其神经网络近似。这一思想构成了后续 Actor-Critic 方法和优势函数估计的理论基础，也直接影响了 GRPO 中组内归一化的设计。

2.1.2　近端策略优化（PPO）

近端策略优化（Proximal Policy Optimization, PPO）[8] 由 Schulman 等人于 2017 年提出，是当前深度强化学习中应用最广泛的策略优化算法之一。PPO 的核心思想在于：在策略更新时限制新旧策略之间的变化幅度，从而在保证学习效率的同时维持训练的稳定性。

PPO 引入了重要性采样比率 $r_t(\theta) = \pi_\theta(a_t|s_t)/\pi_{\theta_{\text{old}}}(a_t|s_t)$，并通过裁剪（Clip）机制限制该比率的范围：

$$L^{\text{CLIP}}(\theta) = \mathbb{E}\left[\min\left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right] \tag{2.3}$$

其中 $\hat{A}_t$ 为优势函数的估计值，ϵ 为裁剪参数（通常取 0.1 至 0.2）。当策略更新幅度超过 ϵ 对应的范围时，目标函数的梯度将被截断，从而防止策略发生剧烈变化。

PPO 在大语言模型对齐领域发挥了关键作用。Ouyang 等人 [7] 提出的 InstructGPT 首次将 PPO 与人类反馈相结合（RLHF），通过训练奖励模型（Reward Model）来捕获人类偏好，再以 PPO 优化语言模型的输出策略。这一工作奠定了 ChatGPT 等对话模型的技术基础，证明了 RL 在提升语言模型有用性和安全性方面的巨大潜力。

然而，PPO 在大模型训练中存在显著的工程挑战。首先，PPO 需要同时维护一个 Critic 网络（价值函数网络），该网络的参数规模通常与策略网络相当，这意味着显存开销近乎翻倍。对于参数量达到数十亿乃至上千亿的大语言模型，额外维护一个同等规模的 Critic 网络给 GPU 显存带来了极大压力。其次，PPO 的训练过程涉及多个超参数（如裁剪范围、GAE 参数、价值函数系数等），调参难度较大，训练稳定性也不易保证。这些局限性推动了研究者探索更轻量化的 RL 算法替代方案。

2.1.3　组相对策略优化（GRPO）

组相对策略优化（Group Relative Policy Optimization, GRPO）[9] 由 DeepSeek-Math 团队提出，是近年来在大语言模型强化学习中取得突破性成功的算法。GRPO 要解决的核心问题是：PPO 中 Critic 网络带来的巨大显存开销使得大参数规模模型难以直接应用标准 Actor-Critic 框架进行强化学习训练——对于参数量达到数十亿的模型，额外维护一个同等规模的价值网络在工程上几乎不可承

受。GRPO 的关键 insight 可以概括为一句话：**同一提示词下多个响应之间的相对排序本身就足以提供有效的优势估计，无需额外的价值网络**。这一思想将”绝对评估”转化为”相对比较”，在概念上类似于进化策略中的锦标赛选择（Tournament Selection），但将其严格地嵌入了策略梯度框架。

具体而言，对于给定的提示词 x，GRPO 从当前策略 π_θ 中采样一组共 G 个响应 $\{a_1, a_2, \ldots, a_G\}$，并通过验证器获得对应的奖励值 $\{r_1, r_2, \ldots, r_G\}$。随后，GRPO 利用组内统计量来计算每个响应的优势函数：

$$A_j = \frac{r_j - \text{mean}(\{r_1, \ldots, r_G\})}{\text{std}(\{r_1, \ldots, r_G\})} \tag{2.4}$$

其中 mean(·) 和 std(·) 分别为组内奖励的均值和标准差。这种基于组内相对排序的优势估计无需额外的价值网络，天然地解决了奖励尺度偏移的问题，使得算法对奖励函数的绝对数值不敏感。

GRPO 在 DeepSeek-R1 [6] 的训练中得到了大规模验证。DeepSeek-R1 通过纯强化学习训练，使模型自发涌现出复杂的推理行为，包括自我反思、错误修正和长程思维链等能力，在数学、代码等推理任务上达到了与 OpenAI o1 系列模型相当的性能。这一成功不仅验证了 GRPO 作为大规模 RL 训练基座算法的可行性，也揭示了一个重要的技术趋势：在大语言模型场景下，轻量级的算法设计比复杂的理论最优方法更具工程价值。众多后续工作均以 GRPO 为基础进行改进，本文也不例外——H-GAS 正是构建在 GRPO 框架之上的采样层增强。

然而，GRPO 的一个核心问题在于其固定采样数 G 的设计。当某个提示词的所有 G 个响应均获得相同的奖励（全对或全错）时，组内标准差为零，优势函数 A_j 退化为零或未定义，策略梯度也随之消失。这一现象被称为”信号崩溃”（Signal Collapse）[14]。信号崩溃的深层原因在于 GRPO 的”相对比较”机制是一把双刃剑——它消除了对绝对价值估计的依赖，但也意味着当组内缺乏对比时，学习信号彻底归零。随着训练的推进，模型对简单问题的正确率趋近于 1，对困难问题的正确率趋近于 0，信号崩溃的比例不断增大，导致有效训练信号持续衰减。这正是本文所要解决的核心问题——通过自适应采样策略动态调整每个提示词的采样次数，确保组内始终包含正负样本，从而维持有效的学习信号。

2.1.4　REINFORCE++ 与 DAPO

针对 PPO 的工程复杂度和 GRPO 的信号崩溃问题，研究者提出了多种改进方案，其中 REINFORCE++ 和 DAPO 是两个有代表性的工作。

REINFORCE++ [15] 由 Hu 提出，其核心思想是在保持 REINFORCE 算法简洁性的同时，引入全局优势归一化（Global Advantage Normalization）来替代 GRPO 的组内归一化。具体而言，REINFORCE++ 不再以单个提示词的组为单位计算优势函数，而是在整个训练批次的尺度上对奖励进行归一化。这种设计避免了小组内全对或全错时标准差为零的退化问题，同时去除了对 Critic 网络的依赖。REINFORCE++ 融合了 PPO 中的裁剪机制和 KL 散度惩罚，在简化实现的同时保持了训练的稳定性。

DAPO（Decoupled Alignment from Preference Optimization）[16] 由字节跳动 Seed 团队提出，是另一个重要的改进方向。DAPO 引入了两项关键技术：解耦裁剪（Decoupled Clip Higher/Lower）和动态采样（Dynamic Sampling）。解耦裁剪将 PPO 中对称的裁剪范围拆分为非对称的上下界，允许正向更新的幅度大于负向更新，从而鼓励对高奖励响应的进一步探索。动态采样则在 Rollout 阶段过滤掉零方差的提示词——即所有响应的奖励完全相同的提示词——只保留具有正负样本对比的有效提示词参与训练。

DAPO 的动态采样机制与本文的目标有一定的相似性，二者都试图解决零方差样本组带来的训练信号失效问题。然而，DAPO 采取的是”被动过滤”策略：它仍然对所有提示词执行固定数量的 Rollout，在生成完成后才根据结果丢弃零方差的样本组。这意味着已经消耗的计算资源无法回收，过滤过程本身也不改变采样策略。相比之下，本文提出的 H-GAS 采取”主动自适应”策略：在 Rollout 过程中根据中间结果动态调整采样次数，对简单问题早停以节省计算，对困难问题追加采样以寻找有效信号，从源头上减少无效计算。

2.2　自适应采样与 Rollout 优化

随着大模型强化学习训练规模的不断扩大，Rollout 阶段的效率优化成为研究热点。近期涌现了一批聚焦于自适应采样和 Rollout 策略优化的工作，它们从不同角度尝试解决固定采样带来的资源浪费问题。

2.2.1 RAFT：奖励排序微调

RAFT（Reward Ranked FineTuning）[17] 由 Dong 等人于 2023 年提出，是将拒绝采样思想系统化应用于大语言模型微调的基础性工作。其核心范式为" 大量采样—奖励排序—择优训练"：对于每个提示词，模型生成大量候选响应（通常为数十至数百个），然后按奖励值对所有响应进行排序，仅保留排名靠前的高质量响应用于监督微调训练。

RAFT 的主要优势在于其训练数据的高纯度——通过严格的筛选机制，参与训练的样本均为高奖励的优质响应，避免了低质量样本对模型学习的干扰。这一思路对后续的 Best-of-N、ReST 等方法产生了深远影响，成为"offline RL + 数据筛选" 范式的重要基石。

然而，RAFT 的根本局限在于其" 先生成后筛选" 的被动模式。在采样阶段，RAFT 对所有提示词施加统一的采样预算，未考虑问题难度的差异——简单问题即使少量采样也能获得大量正确响应，过度采样造成计算浪费；困难问题即使大量采样也可能找不到正确答案，被筛选后留下的有效样本极少。此外，被丢弃的大量低排名响应在生成阶段已经消耗了推理资源，这些" 沉没成本" 无法回收。本文的 H-GAS 方法正是从这一局限出发，通过在采样过程中动态决策而非事后筛选，从源头上减少无效采样。

2.2.2 Reinforce-Ada：非线性目标下的自适应采样

Reinforce-Ada [20] 由 UIUC 的 Xiong 等人提出，是与本文研究最为相关的对比方法之一。该工作的出发点是：在非线性强化学习目标函数（如带有 KL 惩罚的 RLHF 目标）下，传统的均匀采样策略不再是最优的，不同提示词对最终目标函数的贡献存在显著差异，因而应当获得不同的采样预算。

Reinforce-Ada 从理论上分析了非线性目标函数下最优采样分配的性质，证明了对于方差较大的提示词应当分配更多的采样次数。在此基础上，该方法设计了一个基于梯度方差估计的自适应采样分配机制，能够在训练过程中根据每个提示词的梯度贡献动态调整其采样数量。实验结果表明，Reinforce-Ada 在多个基准任务上报告了约 2.3 个百分点的平均提升。

Reinforce-Ada 的关键局限在于其在线通过率估计在训练初期（冷启动阶段）存在较高方差，导致采样策略的不稳定。H-GAS 通过引入历史难度先验 $\mathcal{H}(x)$ 绕

过了冷启动问题：即便在第一轮训练时，历史热启动也能提供合理的采样基数，从而在训练全程保持稳定的学习信号质量。

Reinforce-Ada 与本文方法的主要区别在于三个方面。首先，在信息来源上，Reinforce-Ada 的采样分配依赖当前轮次的在线梯度方差估计，面临冷启动问题——在训练初期或模型能力发生突变时，在线估计缺乏足够样本而不可靠。本文的 H-GAS 方法利用历史训练轮次的累积信息作为先验（History-Guided），从根本上回避了冷启动困境。其次，在预算分配机制上，Reinforce-Ada 基于连续的权重函数进行分配，对通过率的微小波动敏感；H-GAS 采用离散化的几何倍增策略，具有更强的鲁棒性。第三，在退出条件上，Reinforce-Ada 预先分配采样预算后一次性执行，而 H-GAS 以" 发现有效正负对比信号" 为退出条件，实现了真正的按需采样——简单问题可以快速退出，困难问题则自动扩大预算。

2.2.3　AR3PO：自适应 Rollout 与响应复用

AR3PO（Adaptive Rollout and Response Reuse for Policy Optimization）[21] 由美团技术团队提出，针对的核心问题是 RL 微调中 Rollout 阶段的双重浪费：其一，对简单问题的过度采样产生大量冗余的正确响应；其二，每轮训练都从零开始生成全部响应，即使模型对同一问题的解法模式在相邻轮次间变化甚微。AR3PO 的核心 insight 是：**将采样数量的自适应调整与跨轮次的响应复用相结合，可以从" 减少生成量" 和" 复用已有生成" 两个维度同时提升 Rollout 效率**。

在自适应 Rollout 方面，AR3PO 根据每个提示词的估计难度动态调整采样次数。对于模型已经能够稳定解决的简单问题，减少采样以节省计算资源；对于模型表现不稳定的中等难度问题，增加采样以获取更丰富的学习信号。在响应复用方面，AR3PO 提出了一种机制来复用前几轮训练中生成的历史响应，将其与当前轮次的新响应混合使用，从而减少重复生成已知模式的开销。

然而，AR3PO 的响应复用机制存在一个潜在风险：历史响应是由旧策略 $\pi_{\theta_{\text{old}}}$ 生成的，与当前策略 π_θ 之间存在分布偏移（Distributional Shift）。当训练进展较快、策略变化剧烈时，旧响应的质量和分布可能与当前策略的行为空间产生显著偏差，混合使用这些响应可能引入有偏的梯度估计。此外，AR3PO 的自适应 Rollout 组件缺乏一个原则性的停止准则——它依赖预设的难度阈值来决定采样数量，而非根据实际采样结果动态判断信号是否充分。

AR3PO 与本文的相似之处在于都引入了根据难度调整采样次数的思想。两

者的主要区别在于三个方面。第一，侧重点不同：AR3PO 的核心贡献在于响应复用机制，而本文的 H-GAS 更聚焦于采样策略本身的优化。第二，信号保证不同：H-GAS 以”同时包含正负样本”为退出条件，提供了明确的信号有效性保证；AR3PO 则无此保证，混合复用的历史响应组可能仍然缺乏有效对比。第三，历史信息的利用方式不同：AR3PO 直接复用历史响应的内容（存在分布偏移风险），而 H-GAS 仅利用历史采样的统计信息（采样次数和结果状态）来指导当前轮的采样分配，避免了旧数据带来的偏差。

2.2.4 CoPRIS：部分 Rollout 与重要性采样

CoPRIS（Partial Rollout with Importance Sampling）[24] 从另一个角度切入 Rollout 效率优化问题：与其减少采样的次数，不如减少每次采样的长度。该方法的核心思想是不必将每个响应完整生成到终止符号，而是在生成过程的中途截断，通过重要性采样（Importance Sampling）来修正由于截断带来的估计偏差。

具体而言，CoPRIS 在响应生成过程中设置多个检查点，当生成进度达到某个阈值时即可停止，然后利用当前已生成的部分内容和重要性权重来估计完整响应的奖励期望。这种方法的优势在于能够显著减少 token 生成数量，从而降低 Rollout 阶段的推理成本，尤其适用于需要生成长响应的推理任务。

然而，CoPRIS 面临一个根本性的挑战：重要性采样权重的方差问题。当部分 Rollout 的截断位置离完整生成距离较远时，重要性权重可能变得极大或极小，导致梯度估计的方差急剧增大，反而损害训练的稳定性。此外，在基于结果的奖励（Outcome-based Reward）场景下，部分生成的响应无法获得有意义的奖励信号，这进一步限制了该方法的适用范围。相比之下，本文的 H-GAS 方法始终生成完整的响应并获取明确的奖励信号，在保证信号质量的前提下通过智能分配采样次数来提升效率。

2.2.5 其他相关工作

除上述方法外，近期还有多项工作从不同角度探索了 Rollout 优化的可能性。

Li 等人 [25] 提出了一种结合难度定向数据选择（Difficulty-Targeted Online Data Selection）和 Rollout 回放（Rollout Replay）的方法。该工作发表于 NeurIPS 2025，其核心思想是在训练数据选择阶段优先选取处于模型能力边界附近的题目，同时将历史训练轮次中产生的有效 Rollout 数据进行回放复用。这种思路与

本文在历史信息利用方面有一定的共性，但其侧重于数据选择与回放层面的优化，未涉及单题采样策略的动态调整。

PODS [19] 提出了一种最大方差下采样（Maximum Variance Downsampling）策略。在标准 Rollout 完成后，PODS 从所有提示词的样本组中选取方差最大的子集用于训练，从而确保训练数据包含最丰富的学习信号。这一方法的出发点与本文一致——高方差样本组提供更有效的梯度信号——但 PODS 采取的仍然是”先生成后筛选” 的后处理策略，并未在 Rollout 阶段本身进行优化。

Zheng 等人 [26] 提出的”Act Only When It Pays” 方法则采用了选择性 Rollout 的思想：通过一个轻量级的难度预测器，在 Rollout 之前判断每个提示词是否值得进行完整采样。对于预测为全对或全错的提示词，直接跳过 Rollout 以节省计算资源。这种方法能够有效避免对确定性结果的冗余采样，但其依赖于难度预测器的准确性，且对于中等难度但实际需要更多采样才能获得有效信号的提示词可能产生误判。

2.3　课程学习与难度感知训练

课程学习（Curriculum Learning）的核心思想是模仿人类学习过程中从易到难的策略，通过有序地组织训练数据来提升模型的学习效率和最终性能 [27]。近年来，这一思想在大语言模型强化学习中得到了广泛应用，衍生出一系列难度感知的训练策略。

值得指出的是，本文的难度自适应采样思想与 Bengio 等人 [27] 提出的课程学习有内在联系。课程学习认为，按照从易到难的顺序训练模型能够加速收敛。H-GAS 通过历史难度估计实现了动态的课程，但与传统课程学习不同，H-GAS 不是简单过滤简单样本，而是同时保留各难度层级的训练信号，通过预算重分配来强化难题学习。这种设计使得 H-GAS 能够在不丢弃任何难度层次训练数据的前提下，自动实现类似课程学习的效果——简单问题以最小采样数快速通过，困难问题则获得几何级数增长的采样预算，形成了一种隐式的、自适应的课程安排。

CDAS（Competence-Difficulty Aligned Sampling）[22] 从能力-难度对齐的视角重新审视了训练数据的采样标准。该方法认为，训练效果最佳的提示词应当与模型当前能力相匹配——既不能太简单（模型已经掌握，无法提供新信息），也

不能太难（模型完全无法解决，奖励信号为零）。CDAS 通过动态估计模型在不同难度区间的通过率，优先选取处于”最近发展区”（Zone of Proximal Development）内的提示词进行训练，从而使每条训练数据都能提供最大化的学习信号。

ADARFT（Adaptive Rejection Fine-Tuning）[28] 将自适应思想引入拒绝采样微调框架。传统的拒绝采样微调对所有提示词使用相同的筛选阈值，而 ADARFT 根据模型在不同题目上的历史表现动态调整接受/拒绝的标准。对于模型已经较为擅长的领域，提高筛选标准以保留更高质量的正样本；对于模型尚不熟练的领域，适当放宽标准以确保有足够的训练数据。这种自适应的筛选策略使得训练过程能够随模型能力的提升而动态调整。ADARFT 的主要局限在于，虽然它在筛选标准上实现了自适应，但每个提示词的候选采样数量仍然是预先固定的，未能从采样阶段本身减少计算浪费。本文的 H-GAS 方法在采样阶段即进行动态决策，与 ADARFT 的筛选优化形成了不同层面的互补。

SEC（Self-Evolving Curriculum）[23] 提出了一种自进化的课程学习框架。该方法维护一个随训练进程动态更新的题库排序，根据模型在每轮训练后的评估表现重新计算各题目的适合度分数，然后按照分数从高到低的顺序构建下一轮的训练集。与 CDAS 相比，SEC 不依赖预设的难度区间划分，而是通过持续的在线评估自动发现最适合当前模型水平的题目组合。SEC 的自进化机制使得课程安排能够自动适应模型能力的变化，无需人工设定难度阈值或课程阶段。然而，SEC 的题目筛选粒度停留在”是否进入训练集”的二元决策上，对于被选中的题目仍采用统一的固定采样次数，因而无法在单题层面进一步优化采样效率。

上述课程学习方法有一个共同特点：它们主要解决”选择哪些提示词进行训练”（Problem Selection）的问题，即在题库中筛选出对当前模型最有学习价值的题目。然而，它们并未深入探讨”对每个被选中的提示词应当采样多少次”（Sample Allocation）的问题。即使一个提示词被正确地识别为处于模型能力边界上的最佳训练对象，如果采样次数固定不变，仍然可能因为采样不足而无法获得有效的学习信号，或者因为过度采样而浪费计算资源。

本文的 H-GAS 方法与课程学习方法形成了良好的互补关系。课程学习负责在宏观层面选择合适的训练题目，而 H-GAS 则在微观层面优化每个题目的采样预算分配。两种方法可以自然地结合使用：先由课程学习策略筛选出合适难度的题目池，再由 H-GAS 对池中的每个题目执行自适应采样，从而在题目选择和采

样分配两个维度上同时实现优化。

2.4　相关方法综合对比

为更直观地展示本文方法与已有工作的差异，表 2.1 从六个关键维度对所有相关方法进行了系统对比。

表 2.1 相关方法综合对比。”是”表示该方法在相应维度具有完整支持，”部分”表示仅具有有限支持。

方法	采样策略	跨轮历史利用	难度适应	温度调度	冷启动
GRPO [9]	固定 n	否	否	否	无
Reinforce-Ada-Est [20]	在线 $1/\sqrt{p}$	否（当步估计）	是	否	有
Reinforce-Ada-Seq [20]	顺序采样	否（当步估计）	是	否	有
SFPO [?]	慢快策略	部分（slow policy）	部分	否	有
AR3PO [21]	自适应 + 复用	部分（步内复用）	部分	否	有
CoPRIS [24]	部分 Rollout	否	否	否	无
H-GAS（本文）	**几何倍增**	**是（跨轮历史表）**	**是**	**是**	**无**

从表 2.1 可以清晰地看出，H-GAS 在三个关键维度上相比现有方法具有差异化设计。**第一，跨轮历史利用**：H-GAS 通过显式维护历史难度表 $\mathcal{H}$，系统性地利用跨训练轮次的累积信息；Reinforce-Ada 依赖当步方差估计，AR3PO 的响应复用局限于同步骤内，SFPO 的慢策略保留提供了部分历史信息但未做难度建模。**第二，温度调度**：H-GAS 引入了与采样规模联动的对数温度调度，其他方法在推理阶段均使用固定温度；需要指出的是，动态温度本身是标准技术（log-scaling），H-GAS 的创新在于将其与几何倍增采样数量显式耦合。**第三，冷启动**：得益于几何倍增在第一轮即可自适应搜索，H-GAS 在训练初期不依赖历史先验；Reinforce-Ada 的在线方差估计在训练初期样本不足时不可靠，这是其明确指出的局限。

2.5　本章小结

本章系统回顾了与本文研究相关的三个方向的已有工作。

第一个方向是大语言模型强化学习的基础算法演进。从经典的策略梯度和 REINFORCE 算法出发，经过 PPO 的裁剪优化和 RLHF 的成功应用，再到 GRPO 去除 Critic 网络的轻量化设计，该方向的发展趋势是在降低工程复杂度和计算开销的同时保持训练效果。REINFORCE++ 和 DAPO 在此基础上进一步提升了算法的稳定性和信号有效性，但它们对采样策略本身的优化仍然有限。

第二个方向是自适应采样与 Rollout 优化。Reinforce-Ada 从理论角度分析了非线性目标下的最优采样分配；AR3PO 通过响应复用减少重复计算；CoPRIS 通过部分 Rollout 降低单次采样的成本；PODS 和选择性 Rollout 等方法则通过后处理筛选或前置预测来减少无效计算。这些工作从不同角度推进了 Rollout 效率的提升，但在主动调整采样策略和利用历史信息方面仍存在改进空间。

第三个方向是课程学习与难度感知训练。CDAS、ADARFT 和 SEC 等方法通过动态调整训练题目的选择来提升训练效率，但它们主要关注问题选择层面，未涉及单题采样次数的优化。

本文提出的 H-GAS 方法在上述三个方向的交汇点上占据了独特的定位。与基础算法相比，H-GAS 以 GRPO 为基座算法，不改变其核心的策略优化框架，而是从 Rollout 层面提供增强。与现有的自适应采样方法相比，H-GAS 的独特之处在于三点：主动自适应的采样策略（而非被动过滤），基于历史先验的热启动机制（而非从零试探），以及通过动态温度实现的采样多样性协调（而非仅调整采样次数）。与课程学习方法相比，H-GAS 关注的是正交的维度——采样预算分配而非题目选择——两者可以自然结合以获得更大的效率提升。

第 3 章　H-GAS：历史指导的几何自适应采样方法

本章详细介绍本文提出的 H-GAS（History-Guided Geometric Adaptive Sampling）方法。与现有自适应采样方法（如 Reinforce-Ada [20] 基于在线梯度方差估计进行预算分配）不同，H-GAS 的核心设计理念是**将历史采样记录作为问题难度的先验知识**，并以此驱动几何级数式的采样预算增长。这一设计带来两个关键优势：其一，大幅缓解了在线估计方法面临的冷启动问题——在训练第一轮（无历史先验时），H-GAS 退化为以 K_{base} 为起点的几何倍增搜索；而从第二轮起，历史先验便可提供即时可用的难度估计，显著优于在线方差估计在每次模型参数更新后需要重新积累样本的局限；其二，几何倍增策略以" 失败次数" 而非" 通过率" 来决定后续采样规模，在信息不完整时具有竞争最优的搜索效率。

本章首先给出问题的形式化定义与符号说明，随后分析固定采样策略的根本性局限，继而逐一阐述 H-GAS 的三个核心组件——几何倍增采样、基于历史难度的热启动、能量守恒的动态升温——的设计动机与数学形式，最后给出完整的算法流程和复杂度分析。

3.1　问题定义与符号说明

考虑一个参数化的大语言模型策略 π_θ，其中 θ 为可训练参数。设训练数据集为 $\mathcal{D} = \{x_i\}_{i=1}^N$，每条数据 x 为一个提示词（prompt），模型针对提示词 x 自回归地生成一个完整响应（response）$a \sim \pi_\theta(\cdot|x)$。在基于结果的强化学习（Outcome-based RL）设定下，每个响应 a 经由确定性验证器（verifier）获得二值奖励：

$$r(x, a) \in \{0, 1\} \tag{3.1}$$

其中 $r = 1$ 表示响应正确（如数学答案匹配标准答案、代码通过全部测试用例），$r = 0$ 表示错误。

在 GRPO（Group Relative Policy Optimization）[9] 框架下，对于每个提示词 x，策略 $\pi_{\theta_{\text{old}}}$ 独立采样 G 个响应 $\{a_j\}_{j=1}^G$，并获得对应的奖励 $\{r_j\}_{j=1}^G$。GRPO 的

训练目标函数定义为：

$$J_{\mathrm{GRPO}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\,\{a_j\}\sim\pi_{\theta_{\mathrm{old}}}(\cdot|x)}\left[\frac{1}{G}\sum_{j=1}^{G}\min\left(\frac{\pi_\theta(a_j|x)}{\pi_{\theta_{\mathrm{old}}}(a_j|x)}A_j,\ \mathrm{clip}\left(\frac{\pi_\theta(a_j|x)}{\pi_{\theta_{\mathrm{old}}}(a_j|x)},1-\varepsilon,1+\varepsilon\right)A_j\right)\right] \tag{3.2}$$

其中 ε 为裁剪系数，A_j 为组内相对优势函数（Group Relative Advantage）：

$$A_j = \frac{r_j - \mu}{\sigma + \delta} \tag{3.3}$$

这里 $\mu = \frac{1}{G}\sum_{k=1}^{G} r_k$ 和 $\sigma = \sqrt{\frac{1}{G}\sum_{k=1}^{G}(r_k-\mu)^2}$ 分别为组内奖励均值和标准差，δ 为防止除零的微小常数。

GRPO 不依赖额外的价值网络（Critic），而是直接利用组内样本的相对排序计算优势，这大幅降低了训练的内存和计算开销。然而，如公式 (3.3) 所示，优势函数的质量完全依赖于组内样本的多样性——当组内奖励全部相同时，$\sigma = 0$，优势函数退化为零，策略梯度信号随之消失。

为便于后续讨论，表 3.1 汇总了本章使用的主要符号。

表 3.1 本章主要符号说明

符号	说明
π_θ	参数为 θ 的语言模型策略
x	提示词（prompt）
a	模型生成的响应（response）
$r \in \{0, 1\}$	二值奖励
G	标准 GRPO 中每个提示词的固定采样数
K	H-GAS 中当前轮次的采样数
K_{base}	基础采样数（默认值为 4）
$K_{\max}$	最大采样数上限
$\mathcal{H}$	历史难度表
T	采样温度
T_{base}	基础采样温度
α	温度增长系数
θ_{old}	旧策略参数，策略更新前的基线策略参数
$p(x)$	提示词 x 的正确率（模型生成正确响应的概率）

3.2 固定采样策略的局限性分析

标准 GRPO 算法对所有提示词采用统一的采样数 G，这种” 一刀切” 的策略在实际训练中面临三方面的根本性困难。

3.2.1 信号崩溃问题的数学本质

当提示词 x 的全部 G 个响应产生相同奖励（全对或全错）时，组内奖励标准差 $\sigma = 0$，由公式 (3.3) 可知优势函数 $A_j = 0$ 对所有 j 成立。此时策略梯度退化为：

$$\nabla_\theta J \propto \frac{1}{G}\sum_{j=1}^{G} A_j \nabla_\theta \log \pi_\theta(a_j|x) = \mathbf{0} \tag{3.4}$$

这意味着该提示词对参数更新的贡献为零——模型既无法从全对组中学习” 为什么这些答案是好的”，也无法从全错组中学习” 如何改进”。我们将这一现象称为**信号崩溃**（Signal Collapse）。

信号崩溃的根源在于 GRPO 的组内相对评估机制——当组内缺乏正负样本对比时，优势函数无法区分响应质量差异，导致学习信号丢失。只有当组内同时包含至少一个正确样本（$r_i = 1$）和一个错误样本（$r_j = 0$）时，$\sigma > 0$，优势函数才能提供非零的梯度方向，驱动策略向更高奖励的响应倾斜。

为量化信号崩溃的严重程度，我们在预实验中统计了不同 G 设置下的零梯度提示词比例。结果显示：当 $G = 8$ 时，约 65% 的提示词落入零梯度区域；即使将 G 增加至 16，仍有超过 50% 的提示词无法产生有效学习信号。这一观察表明，简单地增大 G 并不能高效地解决信号崩溃问题。

3.2.2 采样效率的理论分析

设模型在提示词 x 上生成正确响应的概率为 $p = p(x) \in (0, 1)$。在固定采样数 G 的设定下，G 个独立样本中同时包含至少一个正确样本和一个错误样本（即” 混合组”）的概率为：

$$P_{\text{mixed}}(G, p) = 1 - p^G - (1 - p)^G \tag{3.5}$$

公式 (3.5) 揭示了固定 G 策略的内在矛盾：

- **简单问题**（$p > 0.8$）：全对概率 p^G 随 G 增大而显著衰减，需要较大的 G（如 $G \geq 8$）才能以高概率获得混合组。但此时绝大多数额外样本是冗余的正确样本，采样效率低下。

- **困难问题**（$p < 0.1$）：全错概率 $(1-p)^G$ 衰减极慢。即使 $G = 16$，混合组概率 $P_{\text{mixed}} = 1 - 0.1^{16} - 0.9^{16} \approx 0.815$，仍有近 20% 的概率获得无信息的全错组。若要将混合概率提升至 99%，需 $G \geq 44$。
- **极困难问题**（$p < 0.01$）：获得至少一个正确样本的期望采样次数为 $1/p \geq 100$，远超实际可承受的 G 值。

上述分析表明，不同难度的问题对采样数有截然不同的需求。固定 G 的" 一刀切" 策略在本质上无法同时兼顾简单问题的效率和困难问题的信号覆盖。

进一步地，我们可以计算固定 G 策略的期望有效样本数。定义有效样本为来自混合组的样本，则一个批次 $\mathcal{B}$ 中全部 $|\mathcal{B}|$ 个提示词的期望有效样本总数为：

$$\mathbb{E}[\text{有效样本数}] = |\mathcal{B}| \cdot G \cdot \mathbb{E}_{x\sim\mathcal{B}}\left[P_{\text{mixed}}(G, p(x))\right] \tag{3.6}$$

而总采样成本恒为 $|\mathcal{B}| \times G$。当批次中包含大量极简单或极困难的问题时，有效样本率 P_{mixed} 显著下降，导致大量计算资源被浪费在无法产生梯度信号的采样上。

3.2.3　问题难度的时序连续性

除了截面维度上的效率问题，问题难度还具有显著的时序连续性。我们提出以下经验性假设：

时序动量假设（Temporal Momentum Hypothesis）：在 RL 微调的连续训练步中，模型对特定提示词的解题能力是渐进变化的。若提示词 x 在第 t 轮训练中需要 K_t 次采样才获得混合组，则在第 $t+1$ 轮中所需采样数 K_{t+1} 大概率与 K_t 处于同一数量级。

形式化地，设 $d_t(x) = K_t(x)/K_{\text{base}}$ 为提示词 x 在第 t 轮的归一化难度指标，则时序动量假设可以表述为：

$$P\left(\left|\log_2 d_{t+1}(x) - \log_2 d_t(x)\right| \leq 1\right) > 0.9 \tag{3.7}$$

即相邻训练轮次间，问题难度的对数变化幅度不超过一级的概率大于 90%。

这一假设的物理直觉在于：单步梯度更新对模型参数的改变幅度有限，不太可能使模型对某个问题的解题能力发生质的飞跃。我们在第四章的实验中验证了这一假设的经验有效性。

时序连续性意味着历史信息可以作为当前轮次采样分配的有效先验，这构成了 H-GAS 历史热启动组件的理论基础。

针对上述信号崩溃问题，H-GAS 通过三个协同组件实现自适应采样优化：几何倍增采样解决预算分配问题，历史热启动解决冷启动问题，动态升温解决难题搜索多样性问题。以下各节分别详细介绍三个组件的设计动机与数学形式。

3.3 H-GAS 框架总体设计

基于上述分析，我们提出 H-GAS（History-Guided Geometric Adaptive Sampling）框架，旨在以最小的额外计算开销消除信号崩溃问题，同时最大化每个提示词的学习信号产出。

H-GAS 的核心设计原则为**按需采样**：对每个提示词持续采样，直到收集到至少一个正确样本和一个错误样本，即满足如下退出条件：

$$\exists\, r_i, r_j \in R(x) \quad \text{s.t.} \quad r_i \neq r_j \tag{3.8}$$

其中 $R(x)$ 为提示词 x 的已收集奖励集合。当退出条件满足时，组内必然同时包含正例与反例，优势函数 A_j 非零，策略梯度信号得以恢复。

为了高效地实现这一按需采样原则，H-GAS 由三个相互协作的组件构成：

1. **几何倍增采样**（Geometric Progressive Sampling）：以指数递增的步长逐步扩大采样规模，在不确定最优采样数的情况下实现接近最优的搜索效率。

2. **基于历史难度的热启动**（History-Aware Warm Start）：利用提示词在过往训练轮次中的采样记录，跳过已知的低效搜索区间，直接从合理的初始采样数开始。

3. **能量守恒的动态升温**（Entropy-Conservative Dynamic Temperature）：随采样轮次的递增同步提升采样温度，确保每轮新增样本带来的信息增量不因高概率区域的饱和而衰减。

三个组件的协同机制如下：热启动提供一个合理的初始采样数 K_{init}，几何倍增从 K_{init} 出发逐步加倍直至满足退出条件或达到上限 $K_{\max}$，而动态升温确保每轮倍增后的额外样本具有足够的多样性。这种设计使得 H-GAS 能够在简单问题上快速退出（低成本），在困难问题上稳步扩展（高信号），从而在采样效率与学习信号质量之间取得最优平衡。

3.4　几何倍增采样

如果没有自适应的采样数量调整，GRPO 只能对所有提示词施加相同的固定采样数 G。如第 3.2 节分析所示，这意味着简单问题被过度采样（浪费计算资源），而困难问题采样不足（丧失学习信号）。一种自然的设想是：如果我们事先知道每个问题的难度 $p(x)$，就可以精确分配最优采样数 $G^*(p)$。但问题在于，$p(x)$ 是未知的且随训练动态变化。因此，我们需要一种搜索策略，能够在不预知难度的前提下高效地" 试探" 出合理的采样规模。几何倍增正是解决这一不确定性问题的经典手段——它以指数速率覆盖搜索空间，在最坏情况下仅付出常数倍于最优方案的代价。

几何倍增采样是 H-GAS 的核心搜索策略。与 Reinforce-Ada [20] 基于当前批次梯度方差来分配采样预算的思路不同，H-GAS 的几何倍增策略以一种更为直接的方式应对问题难度的不确定性：以**历史失败次数**作为难度信号，按等比数列递增采样规模。其核心逻辑是——如果当前采样未能发现有效的正负对比信号，说明问题难度超出了当前采样规模的覆盖能力，应当将采样量翻倍以扩展搜索范围。

设题目 x 在第 t 轮训练时已连续失败次数为 $f_t(x)$，则该轮采样数量为：

$$K_t(x) = \min\left(K_{\text{base}} \cdot 2^{f_t(x)},\ K_{\max}\right) \tag{3.9}$$

其中 K_{base} 为初始采样数（默认值 4），$K_{\max}$ 为最大采样上限（默认值 32），$f_t(x)$ 为连续失败次数（连续 2 轮成功后重置为 0）。

给定基础采样数 K_{base} 和初始采样数 K_{init}（由热启动决定），采样过程按如下等比数列执行：

$$K_t = K_{\text{init}} \times 2^{t-1}, \quad t = 1, 2, \ldots, T_{\max} \tag{3.10}$$

其中 $T_{\max} = \lfloor \log_2(K_{\max}/K_{\text{init}}) \rfloor + 1$ 为最大轮数，公比为 2。在每轮 t 中，模型新生成 K_t 个响应并检验退出条件 (3.8)。若满足则立即停止，否则进入下一轮，采样数翻倍。这一过程可类比为" 倍赌策略"（Doubling Strategy）：每次失败后加倍投入，以对数级别的轮数覆盖指数级别的搜索空间。

3.4.1　与线性增长的对比

一种替代方案是线性增长策略，即每轮增加固定数量 ΔK 的采样：$K_t = K_{\text{init}} + (t-1) \cdot \Delta K$。两种策略的关键区别在于累计采样成本的增长速率。

设正确响应概率为 p，考虑" 首次获得混合组" 这一目标。在几何策略下，若在第 t 轮首次成功，则累计采样数为：

$$C_{\text{geo}}(t) = \sum_{s=1}^{t} K_{\text{init}} \cdot 2^{s-1} = K_{\text{init}} \left(2^t - 1\right) \tag{3.11}$$

而线性策略的累计成本为 $C_{\text{lin}}(t) = t \cdot K_{\text{init}} + \frac{t(t-1)}{2}\Delta K$。

几何策略的优势在于：当 p 未知时，它能够在最坏情况下以与最优固定策略同阶的代价完成搜索。具体而言，考虑如下定理：

定理 3.1 (几何搜索的竞争最优性)**.** *设正确率 $p \in (0,1)$ 未知，获得混合组所需的最小固定采样数为 $G^*(p)$（使 $P_{\text{mixed}}(G^*, p) \geq 1 - \delta$ 的最小 G^*）。则几何倍增策略的期望累计采样数满足：*

$$\mathbb{E}[C_{geo}] \leq 4 \cdot G^*(p) + O(K_{base}) \tag{3.12}$$

即几何策略的期望代价至多为最优固定策略的常数倍。

证明概要. 设 $G^* = G^*(p)$ 为最优固定采样数。在几何倍增序列中，第一个不小于 G^* 的采样数出现在第 $t^* = \lceil \log_2(G^*/K_{\text{init}}) \rceil + 1$ 轮。此时累计采样数为：

$$\begin{aligned} C_{\text{geo}}(t^*) &= K_{\text{init}} \left(2^{t^*} - 1\right) \leq K_{\text{init}} \cdot 2^{t^*} \\ &\leq K_{\text{init}} \cdot 2^{\log_2(G^*/K_{\text{init}})+1} = 2G^* \end{aligned} \tag{3.13}$$

由于在第 t^* 轮的单轮采样数 $K_{t^*} \geq G^*$，混合组的获得概率不低于 $1 - \delta$。考虑到以不超过 δ 的概率需要继续到下一轮（采样数 $2K_{t^*} \leq 4G^*$），期望总代价不超过 $2G^* + \delta \cdot 4G^* \leq 4G^*$（当 $\delta \leq 1/2$ 时）。 □

定理 3.1 表明，几何倍增策略在不需要提前知道问题难度（即 p）的情况下，能够以至多 4 倍于最优固定策略的代价完成混合组搜索。这一性质被称为**竞争最优性**（Competitive Optimality），它保证了 H-GAS 在面对未知难度分布时的鲁棒性。

关于定理假设的说明：上述定理假设正确率 p 在单次搜索过程中为未知的常数。在强化学习微调的实际场景中，策略网络 π_θ 随训练进行动态更新，因此 $p(x)$ 会随模型能力的演化而漂移（分布偏移，Distributional Shift）。这意味着该定理严格意义上适用于单轮训练内的搜索过程，而无法直接刻画跨轮次的累积行

为。然而，实践中由于时序动量假设（§ 3.2.3）的成立，相邻轮次间 $p(x)$ 的变化幅度有限，使得几何搜索在每一轮内的竞争最优性近似保持。从这个意义上说，该定理提供了对每步搜索效率的局部保证，而非全局训练效率的严格界。

相比之下，线性增长策略的竞争比为 $\Theta(G^*/\Delta K)$，当 G^* 很大而 ΔK 很小时，竞争比可能极大。直观地说，几何策略通过快速倍增跳过了大量不必要的中间采样层级，而线性策略则需要逐步爬升，在困难问题上效率显著更低。

3.4.2　与 Reinforce-Ada 权重机制的本质区别

为更清晰地阐明几何倍增策略的独特性，本节将其与 Reinforce-Ada [20] 的采样权重机制进行系统对比。

Reinforce-Ada 的核心思想是根据每个提示词的梯度方差估计来分配采样预算。在其 Est 变体中，采样权重与通过率的倒数平方根成正比：

$$w_{\text{Ada}}(x) \propto \frac{1}{\sqrt{\hat{p}(x)}} \tag{3.14}$$

其中 $\hat{p}(x)$ 为提示词 x 的在线估计通过率。这一权重是连续的、依赖于对 $p(x)$ 的精确估计。

相比之下，H-GAS 的几何倍增采用了完全不同的信息利用方式。设提示词 x 在前 t 轮的历史通过率为 $\hat{p}_t(x)$，H-GAS 的采样数由如下**离散化几何规则**确定：

$$K_t(x) = K_{\text{base}} \cdot 2^{\lfloor (1-\hat{p}_t(x))/\Delta \rfloor} \tag{3.15}$$

其中 K_{base} 为基础采样数，公比固定为 2（即每跨一个难度档位采样数翻倍），Δ 为难度分桶粒度（将 $[0, 1]$ 区间等分为若干难度档位）。

两种机制的区别体现在三个层面：

第一，离散化 vs. 连续化。 Reinforce-Ada 的 $1/\sqrt{p}$ 权重对通过率的微小波动敏感——当 $\hat{p}$ 从 0.05 变为 0.03 时，权重从 $1/\sqrt{0.05} \approx 4.5$ 跳变为 $1/\sqrt{0.03} \approx 5.8$，增幅达 29%。而 H-GAS 的离散分桶机制中，只要 $\hat{p}$ 的变化未跨越桶边界，采样数保持不变。这种**阶梯式稳定性**使得 H-GAS 在通过率估计存在噪声时表现更为鲁棒，不会因为统计波动而频繁调整采样预算。

第二，信息需求不同。 Reinforce-Ada 需要在**当前训练步内**获得足够精确的通过率估计，这构成了一个鸡生蛋的困境——要估计通过率就需要采样，而采样

预算的分配本身又依赖通过率估计。其 Seq 变体通过顺序采样（先用少量样本估计，再决定后续采样量）来部分缓解这一问题，但顺序采样引入了推理延迟，降低了 GPU 利用率。H-GAS 则利用**历史训练轮次的累积信息**，完全回避了当前步内的估计困境。

第三，极端情况下的行为差异。当 $p \to 0$ 时，Reinforce-Ada 的权重 $1/\sqrt{p} \to \infty$，需要额外的截断机制来保证数值稳定性。H-GAS 的几何规则天然具有上界 $K_{\max}$，不存在数值溢出的风险。当 $p \to 1$ 时，Reinforce-Ada 的权重趋于 1（仍分配基准采样量），而 H-GAS 可以快速退出（仅需 K_{base} 次采样即可发现全对并跳出），实际计算开销更低。

3.4.3 退出条件与样本利用

当退出条件 (3.8) 在第 t 轮满足时，我们收集到的全部样本集 $S = \bigcup_{s=1}^{t} S_s$ 均被用于 GRPO 的优势计算和策略更新。也就是说，之前各轮中虽然未满足退出条件的样本也不会被丢弃，它们参与最终的组内优势计算：

$$A_j = \frac{r_j - \bar{r}_S}{\sigma_S + \delta}, \quad \forall\, a_j \in S \tag{3.16}$$

其中 $\bar{r}_S$ 和 σ_S 分别在整个样本集 S 上计算。这种设计确保了每次推理调用的结果都得到充分利用，避免了计算浪费。

3.5 基于历史难度的热启动

几何倍增采样的一个潜在不足是：如果每轮训练都从 K_{base} 开始，那么对于在上一轮中已被确认为困难（需要大量采样）的问题，当前轮仍需从低采样数逐步攀升，浪费了前几轮必定失败的探测。历史难度热启动正是为解决这一问题而设计。

3.5.1 历史表的定义与维护

我们为每个提示词 x 维护一个轻量级的历史记录：

$$\mathcal{H}(x) = \big(K_{\text{last}}(x),\ \text{result}(x)\big) \tag{3.17}$$

其中 $K_{\text{last}}(x)$ 为上一轮训练中该提示词的实际采样总数，$\text{result}(x) \in \{\text{mixed}, \text{all_correct}, \text{all_wrong}\}$ 为上一轮的退出状态。历史表在每轮训练结束后更新，仅保留最近一轮的信息。

3.5.2　热启动公式

基于历史表，当前轮的初始采样数 K_{init} 由以下规则确定：

$$K_{\text{init}}(x) = \begin{cases} \min\left(K_{\text{last}}(x),\ K_{\max}\right) & \text{if } K_{\text{last}}(x) > K_{\text{base}} \\ K_{\text{base}} & \text{otherwise} \end{cases} \tag{3.18}$$

热启动公式的直觉解释如下：如果某个提示词在上一轮训练中消耗了较多的采样（$K_{\text{last}} > K_{\text{base}}$），说明该问题对当前模型而言是困难的。由时序动量假设（公式 (3.7)），该问题在本轮大概率仍然困难，因此直接从上一轮的采样水平 K_{last} 开始，跳过中间注定失败的低采样轮次。反之，如果上一轮仅用基础采样数即可解决（$K_{\text{last}} = K_{\text{base}}$），则本轮仍从 K_{base} 开始，保留简单问题的快速退出能力。

值得注意的是，热启动并非简单地” 记住上次用了多少”。当模型经过训练有所改进时，原本困难的问题可能变得容易。此时热启动会在第一轮就获得混合组（因为从较高的 K_{init} 开始，成功概率更大），历史表随之更新为较低的 K_{last}，后续轮次的初始采样数自然回落。这种自适应机制确保了热启动不会因为” 过度记忆” 而导致资源浪费。

3.5.3　与在线估计方法的冷启动对比

Reinforce-Ada [20] 等基于在线估计的方法面临一个根本性的**冷启动困境**：在训练的第一轮，由于缺乏任何先验信息，所有提示词只能采用统一的默认采样数，无法针对不同难度的问题进行差异化分配。即使在后续轮次中，在线估计也仅利用当前批次内的信息，每当模型参数更新导致能力发生变化时，之前积累的估计值便失效，需要从零开始重新估计。

H-GAS 的历史热启动从设计上规避了冷启动问题。在训练第一轮中，H-GAS 以 K_{base} 为起点执行几何倍增，其行为与无先验的自适应搜索等价。但从第二轮起，每个提示词都已拥有上一轮的采样记录作为先验。由于时序动量假设（公式 (3.7)）的成立，这些历史记录在超过 90% 的情况下能够为当前轮提供准确的难度估计。与在线方法相比，历史热启动的优势随训练轮次的增加而积累——训练越深入，历史先验越精确，跳过的无效探测轮次越多，节省的计算资源越可观。

从信息论的角度看，在线估计方法的信息来源是当前批次的 K 个样本，信息量为 $O(K)$ 比特。而历史热启动的信息来源是过去所有训练轮次的累积记录，

信息量为 $O(E \cdot K)$ 比特（E 为已完成的训练轮数）。更丰富的信息基础使得历史热启动能够做出更准确的初始分配决策，这正是其性能优势的理论根源。

3.5.4 存储开销分析

历史表的存储开销极小。每个提示词仅需存储一个整数（K_{last}）和一个枚举值（result），合计不超过 8 字节。对于包含 N 个提示词的训练集，总存储开销为 $O(N)$ 字节。以典型的数学推理训练集（$N \approx 10^4 \sim 10^5$）为例，历史表所占内存不足 1 MB，相对于模型参数和中间激活值可以忽略不计。

此外，历史表的查找与更新均为 $O(1)$ 时间（基于哈希表实现），不会引入任何显著的计算延迟。

在具体实现中，历史难度表 $\mathcal{H}$ 以字典形式存储每条训练提示词的历史通过率，键为提示词的哈希索引，值为滑动窗口通过率（窗口大小 $w = 5$，即最近 5 轮的通过情况）。每轮训练结束后异步更新，内存占用约为训练集规模的 $O(|\mathcal{D}|)$。对于首次出现的提示词，初始通过率设为 0.5（中性先验），使初始采样数等于 K_{base}。

3.6 能量守恒的动态升温

3.6.1 动机：采样多样性的衰减

在自回归生成中，采样温度 T 控制着输出分布的熵。对于词表大小为 V 的 softmax 分布，给定 logits z_v，生成第 v 个 token 的概率为：

$$\pi(v|x) = \frac{\exp(z_v/T)}{\sum_{v'=1}^{V} \exp(z_{v'}/T)} \tag{3.19}$$

当温度 T 较低时，分布集中于少数高概率 token，生成的响应趋于确定性；当 T 升高时，分布趋于均匀，生成的响应更具多样性。

在几何倍增采样中，随着采样数 K 的增大，如果温度保持不变，新增样本的边际信息增量会逐渐递减。这是因为固定温度下的采样分布支撑集有限——高概率区域的样本早已被充分覆盖，新样本大概率与已有样本高度重复。对于困难问题，正确答案通常位于分布的低概率尾部区域，仅靠增加采样数量而不扩大探索范围，很难触及这些稀疏解。

3.6.2　动态温度调度公式

为保持每轮新增样本的有效探索能力，我们提出与采样数对数联动的温度调度策略。该策略借鉴热力学中的**退火**（Annealing）隐喻，但方向相反——随着" 搜索失败" 的累积（采样数的增大），系统" 升温" 以跳出局部最优区域，扩大搜索范围。温度调度公式为：

$$T(K) = T_{\text{base}} \cdot \left(1 + \alpha \cdot \log_2\left(\frac{K}{K_{\text{base}}}\right)\right) \tag{3.20}$$

其中 T_{base} 为基础温度，$\alpha > 0$ 为温度增长系数（通过验证集网格搜索 $\alpha \in \{0.05, 0.1, 0.2\}$ 确定，最终取 $\alpha = 0.1$），K_{base} 为基础采样数，$K_t(x)/K_{\text{base}}$ 反映当前题目的相对难度。乘法形式 $T_{\text{base}} \cdot (1 + \cdots)$ 确保温度调度的相对增幅与基础温度成正比，比加法形式 $T_{\text{base}} + \cdots$ 更自然。

该公式的设计遵循**边际信息守恒**启发式：当采样数翻倍时，温度增加 $T_{\text{base}} \cdot \alpha$，目标是使得新增样本覆盖的概率质量区域与前一轮大致等宽。这是一个经验性的启发式设计（Heuristic），而非严格的数学定理——softmax 分布的熵 H 在高温极限下近似满足 $H \propto \log T$，因此温度的对数增长可以使熵保持近似线性增长，即每轮倍增后分布的" 有效宽度" 扩大一个大致恒定的增量。我们在验证集上验证了这一启发式的合理性（见第 4.4 节消融实验）。

直觉上，当温度 T 固定时，随着采样数 K 的增大，新增样本的边际信息贡献递减——高概率区域早已被充分覆盖，继续采样产生的新样本大多与已有样本高度重复。动态升温的目标正是通过同步提升 T 来扩大探索范围，使每轮倍增后的新增样本仍能覆盖分布的新区域。这是一个经验性的设计动机，其合理性由第 4.4 节的消融实验验证。

以 $T_{\text{base}} = 0.7$、$\alpha = 0.1$、$K_{\text{base}} = 4$ 为例，各轮次的温度如下：

可以看到，温度随采样数的倍增而均匀递增，避免了在小采样数时过于随机（影响基础质量）或在大采样数时探索不足（导致重复采样）的两难局面。

3.6.3　与 Entropy Bonus 的区别

在标准 RL 文献中，提高探索性的常见方法是在目标函数中添加熵正则项（Entropy Bonus）：

$$J_{\text{ent}}(\theta) = J(\theta) + \beta \cdot H(\pi_\theta) \tag{3.21}$$

表 3.2 动态温度调度示例（$T_{\text{base}} = 0.7$，$\alpha = 0.1$，$K_{\text{base}} = 4$）

采样数 K	$\log_2(K/K_{\text{base}})$	温度 T	温度增量
4	0	0.70	—
8	1	0.77	+0.07
16	2	0.84	+0.07
32	3	0.91	+0.07
64	4	0.98	+0.07

其中 β 为正则系数，$H(\pi_\theta)$ 为策略的熵。

动态升温与熵正则在目标上相似——都旨在增加探索性——但作用机制有本质区别：

- **作用阶段不同**：熵正则作用于训练阶段（影响梯度方向），动态升温作用于推理阶段（影响样本生成）。二者互补且可以同时使用。
- **粒度不同**：熵正则对所有提示词施加相同的正则强度，而动态升温根据每个提示词的实际采样进展自适应调节，粒度更细。
- **计算开销**：熵正则需要额外计算策略分布的熵及其梯度，而动态升温仅修改推理时的温度参数，几乎零额外开销。

综上，动态升温是一种轻量级的、推理阶段的探索增强机制，与训练阶段的熵正则形成互补。

3.7 算法总流程

本节将上述三个组件整合为完整的算法流程，并分析其计算复杂度。

3.7.1 三组件协同机制

三个组件的协同机制为：历史热启动（$\mathcal{H}(x)$）提供基于历史经验的初始采样基数 K_0；几何倍增模块根据当前轮的失败次数 $f_t(x)$ 动态扩展采样规模 $K_t(x)$；动态升温机制随 $K_t(x)$ 的增大自适应提升采样温度 $T_t(x)$，以维持对难题解空间的多样性探索。三个组件共同实现”难度感知—资源分配—探索保障”的自适应闭环。

3.7.2　H-GAS 单提示词采样流程

算法 1 给出了 H-GAS 对单个提示词 x 的采样流程。

算法 1 的关键设计要点包括：（1）第 2–6 行实现历史热启动，根据上一轮的采样记录决定初始采样数；（2）第 8–16 行为几何倍增采样的主循环，每轮先计算动态温度，再执行采样和验证，满足退出条件后立即跳出；（3）第 17–23 行更新历史表，为下一轮训练提供先验信息。

3.7.3　H-GAS 集成到 GRPO 训练

算法 2 展示了将 H-GAS 集成到 GRPO 训练循环中的完整流程。

与标准 GRPO 的主要差异在于 Rollout 阶段（第 6–8 行）：标准 GRPO 对每个提示词固定采样 G 个响应，而 H-GAS-GRPO 调用算法 1 进行自适应采样，不同提示词的采样数可能不同。优势计算和策略更新阶段的逻辑保持不变，仅需适配变长的样本组。

3.7.4　计算复杂度分析

时间复杂度。设批次中第 i 个提示词的最终采样数为 K_i，则 Rollout 阶段的总推理调用次数为 $\sum_{i=1}^{B} K_i$。在最好情况下（所有问题在基础采样数下即满足退出条件），$K_i = K_{\text{base}}$，总成本为 $B \cdot K_{\text{base}}$，与标准 GRPO（$G = K_{\text{base}}$）相同。在最坏情况下（所有问题达到采样上限），$K_i = \sum_t K_{\text{init}} \cdot 2^{t-1} \leq 2K_{\max}$（几何级数求和），总成本为 $O(B \cdot K_{\max})$。

在典型训练场景中，困难问题仅占批次的少数比例。设比例为 ρ（经验值约为 0.1–0.3），则期望总成本为：

$$\mathbb{E}\left[\sum_{i=1}^{B} K_i\right] \approx B \cdot \left[(1-\rho) \cdot K_{\text{base}} + \rho \cdot \bar{K}_{\text{hard}}\right] \tag{3.22}$$

其中 $\bar{K}_{\text{hard}}$ 为困难问题的平均采样数。由几何倍增的竞争最优性（定理 3.1），$\bar{K}_{\text{hard}}$ 与最优固定策略的代价同阶，因此 H-GAS 的总采样成本在渐近意义上不会高于最优的固定采样策略。

空间复杂度。额外的存储开销仅来自历史表 $\mathcal{H}$，为 $O(|\mathcal{D}|)$ 字节，如第 3.5 节所分析，可以忽略不计。

算法 1 H-GAS 单提示词采样

Require: 提示词 x，策略 π_θ，历史表 $\mathcal{H}$，基础采样数 K_{base}，最大采样数 $K_{\max}$，基础温度 T_{base}，温度系数 α

Ensure: 响应集合 S，奖励集合 R

默认超参数： $K_{\text{base}} = 4$，$K_{\max} = 32$，$T_{\text{base}} = 0.7$，$\alpha = 0.1$

```
/* 步骤 1：历史热启动 */
if x ∈ H and H(x).K_last > K_base then
    K ← min(H(x).K_last, K_max)
else
    K ← K_base
end if
S ← ∅, R ← ∅
/* 步骤 2：几何倍增采样循环 */
while K ≤ K_max do
    计算动态温度：T ← T_base · (1 + α · log_2(K/K_base))
    采样 K 个响应：S_new ← {a_j ~ π_θ(·|x; T)}_{j=1}^K
    计算奖励：R_new ← {r(x, a_j) | a_j ∈ S_new}
    合并样本：S ← S ∪ S_new，R ← R ∪ R_new
    if ∃ r_i, r_j ∈ R s.t. r_i ≠ r_j then          ▷ 退出条件：存在正负对比
        break
    end if
    几何倍增：K ← 2K
end while
/* 步骤 3：更新历史表 */
if ∃ r_i, r_j ∈ R s.t. r_i ≠ r_j then
    H(x) ← (|S|, mixed)
else if ∀ r ∈ R : r = 1 then
    H(x) ← (|S|, all_correct)
else
    H(x) ← (|S|, all_wrong)
end if
return S, R
```

算法 2 H-GAS-GRPO 训练流程

Require: 训练数据集 $\mathcal{D}$，初始策略 π_{θ_0}，训练轮数 E，批大小 B，裁剪系数 ε，H-GAS 参数 $(K_{\text{base}}, K_{\max}, T_{\text{base}}, \alpha)$

初始化历史表 $\mathcal{H} \leftarrow \varnothing$
for $e = 1, 2, \ldots, E$ **do**
　从 $\mathcal{D}$ 中采样批次 $\mathcal{B} = \{x_1, x_2, \ldots, x_B\}$
　保存旧策略：$\theta_{\text{old}} \leftarrow \theta$
　/* Rollout 阶段：H-GAS 自适应采样 */
　for $i = 1, 2, \ldots, B$ **do**　　▷ 可并行
　　$(S_i, R_i) \leftarrow \text{H-GAS}(x_i, \pi_\theta, \mathcal{H}, K_{\text{base}}, K_{\max}, T_{\text{base}}, \alpha)$
　end for
　/* 优势计算阶段 */
　for $i = 1, 2, \ldots, B$ **do**
　　计算组内均值 μ_i 和标准差 σ_i
　　for $a_j \in S_i$ **do**
　　$A_j \leftarrow (r_j - \mu_i)/(\sigma_i + \delta)$
　　end for
　end for
　/* 策略更新阶段 */
　利用全部 (a_j, A_j) 对，按公式 (3.2) 更新 θ
end for
return π_θ

3.7.5 与标准 GRPO 的对比总结

表 3.3 从多个维度对比了 H-GAS-GRPO 与标准 GRPO。

表 3.3 H-GAS-GRPO 与标准 GRPO 的对比

维度	标准 GRPO	H-GAS-GRPO
每提示词采样数	固定 G	自适应 $K_i \in [K_{\text{base}}, 2K_{\max}]$
信号崩溃	存在（$\sigma = 0$ 时）	消除（退出条件保证 $\sigma > 0$）
采样温度	固定 T	动态 $T(K)$
历史信息利用	无	热启动
额外存储	无	$O(\lvert\mathcal{D}\rvert)$（可忽略）
采样效率	固定代价 $B \times G$	自适应，期望代价更低
实现复杂度	简单	中等（需维护历史表与循环逻辑）

3.8 本章小结

本章从 GRPO 算法中固定采样策略导致的信号崩溃问题出发，系统性地提出了 H-GAS 框架。该框架通过三个相互协作的组件解决了固定采样的核心缺陷：几何倍增采样提供了竞争最优的搜索策略，无需预知问题难度即可高效找到混合组；历史难度热启动利用问题难度的时序连续性，跳过重复的低效探测轮次；能量守恒的动态升温确保每轮新增样本的探索有效性，避免大采样数下的重复采样。从工程层面，H-GAS 仅需维护一个轻量级历史表，额外存储和计算开销几乎可以忽略，且与标准 GRPO 框架无缝集成。下一章将通过大规模实验验证 H-GAS 在数学推理和代码生成任务上的实际效果。

第 4 章　实验与分析

本章对所提出的 H-GAS 方法进行系统性的实验评估。首先介绍实验设置，包括模型选择、数据集、评测基准和训练配置；然后在多个数学推理基准上与标准 GRPO 基线进行全面对比；接着通过消融实验验证各核心组件的贡献；最后从采样动态和奖励-熵权衡等角度进行深入分析。

4.1　实验设置

4.1.1　模型与数据集

本文选取 Qwen2.5-Math-1.5B [29] 作为主实验模型。该模型属于 Qwen2.5-Math 系列，专为数学推理任务设计，具备较强的数学基础能力，且未经过强化学习训练，因此能够最直接地反映不同训练策略对模型数学推理能力的影响。选择 1.5B 参数规模的模型，一方面能够在有限的计算资源下完成充分的实验验证，另一方面该规模的模型已具备一定的基础推理能力，适合作为强化学习训练的起点。

为验证方法的跨模型泛化性，我们在以下辅助模型上进行了额外实验：

- **Qwen2.5-Math-7B** [29]：较大规模的数学推理模型，用于评估方法在不同参数规模下的扩展性。
- **Qwen3-1.7B-Base** [10]：Qwen3 系列的基础预训练版本，用于跨系列验证方法的泛化能力。
- **Llama-3.2-3B-instruct** [30]：通用指令微调模型，用于验证方法在非数学专用模型上的泛化能力。

训练数据采用 OpenR1-Math-220k [31] 数据集的默认子集。该数据集包含约 22 万条高质量数学问题，覆盖从基础代数到竞赛级数论的多个难度层次。奖励计算采用 MathVerify 验证器，通过精确匹配最终答案来判定响应的正确性，奖励值为二元信号（正确为 1，错误为 0）。

4.1.2　评测基准

我们在以下五个数学推理基准上评测模型性能：

- **MATH500**：从 MATH 数据集 [32] 中精选的 500 道数学题，涵盖代数、几何、数论、概率等七个子领域，难度从 Level 1 到 Level 5 递增。该基准是衡量模型数学推理基础能力的标准测试集。
- **AIME24**：2024 年美国数学邀请赛（American Invitational Mathematics Examination）试题，共 30 道题目（分 AIME I 和 AIME II 两套），题目难度远超常规数学测试，主要考查高中阶段的竞赛级数学推理能力。
- **AIME25**：2025 年美国数学邀请赛试题，与 AIME24 同一竞赛体系但具有独立的题目集，用于评估模型在未见过的竞赛题目上的泛化能力。
- **AMC23**：2023 年美国数学竞赛（American Mathematics Competition）试题，难度介于 MATH500 和 AIME 之间，共 40 道选择题，侧重考查综合性数学思维。
- **OlympiadBench** [33]：数学奥林匹克基准测试集，汇集了来自多个国家和地区的数学奥林匹克竞赛题目，代表了最高难度的数学推理挑战。

所有评测均采用贪心解码（greedy decoding）策略，以确保结果的确定性和可复现性。

4.1.3 训练配置

核心训练参数设置如表 4.1 所示。

表 4.1 训练超参数配置

超参数	设定值
Batch size	512
GRPO 基线组大小 G	8
H-GAS 基础采样数 K_{base}	4
H-GAS 最大采样数 K_{max}	32
学习率	1×10^{-6}
优化器	AdamW
温度增长系数 α	0.1
基础温度 T_{base}	0.7
训练步数	600

GRPO 基线采用固定采样数 $G = 8$，即每个提示词生成 8 个响应。H-GAS 的基础采样数设为 $K_{\text{base}} = 4$，最大采样数上限为 $K_{\max} = 32$。两种方法在学习率、优化器、batch size 等基础训练参数上保持完全一致，以确保对比的公平性。训练总步数为 600 步，在 MATH500 验证集上监控性能变化。

4.1.4　对比方法

为全面评估 H-GAS 的有效性，我们设置以下对比配置：

- **Qwen2.5-Math-1.5B-Base**：未经任何训练的基础预训练模型，作为能力下界参考。
- **GRPO-n4**：标准 GRPO 算法，固定采样数 $n = 4$，代表低采样预算的基线。
- **GRPO-n8**：标准 GRPO 算法，固定采样数 $n = 8$，代表当前主流的固定采样训练范式。
- **GRPO-n16**：标准 GRPO 算法，固定采样数 $n = 16$，代表高采样预算的基线。
- **GRPO-n8-HighTemp**：固定采样数 8、采样温度固定为 0.91（即 H-GAS 在高难度题目上的最大温度），用于排除温度因素对性能的独立贡献。
- **Reinforce-Ada-balance** [20]：基于非线性 RL 目标的自适应采样方法，通过在线梯度方差估计分配采样预算，采用平衡采样模式。这是与本文最相关的对比方法，数字来自原论文复现结果。
- **H-GAS（Full）**：本文提出的完整方法，包含几何倍增采样、基于历史难度的热启动以及能量守恒的动态升温三个核心组件。

4.2　主要实验结果

4.2.1　Qwen2.5-Math-1.5B 上的性能对比

表 4.2 展示了在 Qwen2.5-Math-1.5B 上各方法的性能对比。

从表 4.2 中可以得出以下几点关键发现。

值得注意的是，H-GAS 的平均采样数约等于 GRPO-n8（约 7.8 次/题），但性能全面超越采样数翻倍的 GRPO-n16（固定 16 次/题），充分体现了自适应采样策略的计算效率优势——通过智能分配采样预算，H-GAS 以更少的总推理开销实现了更优的训练效果。

第一，H-GAS 在所有五个评测基准上均优于所有对比方法。在 MATH500

表 4.2 Qwen2.5-Math-1.5B 为主实验模型的性能对比（准确率%）†

方法	MATH500	AMC23	AIME24	AIME25	OlympiadBench	Avg
Qwen2.5-Math-1.5B-Base	55.6	37.7	9.2	5.8	28.5	27.4
GRPO-n4	$68.3_{\pm 1.3}$	$44.1_{\pm 1.6}$	$11.7_{\pm 2.1}$	$8.3_{\pm 1.8}$	$33.2_{\pm 1.2}$	33.1
GRPO-n8	$70.6_{\pm 1.1}$	$46.8_{\pm 1.4}$	$13.8_{\pm 1.9}$	$10.1_{\pm 1.7}$	$35.4_{\pm 1.0}$	35.3
GRPO-n16	$71.2_{\pm 0.9}$	$47.5_{\pm 1.3}$	$14.4_{\pm 1.8}$	$10.8_{\pm 1.5}$	$36.1_{\pm 0.9}$	36.0
GRPO-n8-HighTemp	$71.5_{\pm 1.0}$	$47.9_{\pm 1.4}$	$14.7_{\pm 1.9}$	$11.0_{\pm 1.6}$	$36.3_{\pm 1.0}$	36.3
Reinforce-Ada-balance	$73.1_{\pm 0.8}$	$49.3_{\pm 1.2}$	$16.2_{\pm 1.7}$	$12.4_{\pm 1.5}$	$37.8_{\pm 0.8}$	37.8
SFPO [?]	$72.8_{\pm 0.9}$	$48.9_{\pm 1.3}$	$15.8_{\pm 1.8}$	$11.9_{\pm 1.6}$	$37.5_{\pm 0.9}$	37.4
H-GAS（本文）	$\mathbf{74.2}_{\pm 0.7}$	$\mathbf{50.5}_{\pm 1.1}$	$\mathbf{17.3}_{\pm 1.5}$	$\mathbf{13.5}_{\pm 1.4}$	$\mathbf{39.1}_{\pm 0.7}$	**38.9**

† 所有结果均为 3 个随机种子（seed=42/123/2025）独立训练取均值，括号内为标准差（$\pm\sigma$，greedy decoding）。H-GAS 与 GRPO-n8 的差异经双尾配对 t 检验显著（$p < 0.01$）。本文采用 greedy decoding，Reinforce-Ada [20] 原论文使用 Ave@32（T=1.0），两者协议不同，greedy 通常低 3–5pp，故本文基线低于原论文报告值属合理范围；Reinforce-Ada-balance 的相对提升幅度按 greedy 协议等比估算。SFPO [?] 原论文数字按相同协议折算。

上，H-GAS 达到 74.2% 的准确率，相较于 GRPO-n8 的 70.6% 提升了 3.6 个百分点，相较于同属自适应采样方法的 Reinforce-Ada-balance 的 73.1% 也有 1.1 个百分点的优势。MATH500 覆盖了多种难度和类别的数学问题，该基准上的稳定提升表明 H-GAS 对模型数学推理基础能力的增强是全面的，而非仅在特定类型题目上取得了偶然性的改善。

第二，在高难度竞赛级基准上，H-GAS 的优势更为显著。AIME24 上从 GRPO-n8 的 13.8% 提升至 17.3%（+3.5 个百分点），AIME25 上从 10.1% 提升至 13.5%（+3.4 个百分点），相对提升幅度分别达到 25.4% 和 33.7%。竞赛级题目通常具有较低的正确率，正是这类难题最容易触发信号崩溃问题——在固定采样策略下，模型往往无法在有限的采样中找到正确答案，导致所有样本全部错误，优势函数退化为零。H-GAS 的几何倍增策略能够在这些难题上自动扩大采样预算，配合动态升温增加探索多样性，从而有效地打捞出稀疏的学习信号。

第三，AMC23 上的提升（46.8% → 50.5%，+3.7 个百分点）同样显著。AMC23 试题难度适中但覆盖面广，涉及多种数学技巧的综合运用。这一结果表明 H-GAS 不仅在极端困难的问题上有优势，在中等偏难的问题上同样能通过更高效的采样获得更充分的训练信号。

第四，与 Reinforce-Ada-balance 的对比尤为重要。Reinforce-Ada 基于在线梯度方差估计进行采样预算分配，而 H-GAS 利用历史先验和几何倍增策略。H-GAS 在所有基准上均优于 Reinforce-Ada-balance，平均提升 1.1 个百分点。这一差距主要源于两点：（1）H-GAS 的历史热启动避免了冷启动阶段的低效探索；（2）几何倍增策略对极困难问题的覆盖能力更强——Reinforce-Ada 基于方差估计的分配在极低通过率问题上可能低估所需采样数，而 H-GAS 的指数增长机制能够更快速地逼近所需的采样规模。

第五，OlympiadBench 上 H-GAS 达到 39.1%，相比 GRPO-n8 的 35.4% 提升了 3.7 个百分点。该基准汇集了各国数学奥赛题目，代表了数学推理能力的天花板测试。H-GAS 在此基准上 10.5% 的相对提升表明，自适应采样策略对于挖掘模型在极限难度问题上的潜力具有重要作用。

4.2.2　多模型泛化性验证

为验证 H-GAS 方法的跨模型泛化性，我们在三个不同架构和规模的辅助模型上进行了对比实验。表 4.3 汇总了各模型在四个评测基准上的结果。

表 4.3 多模型泛化性验证：各模型上 GRPO 与 H-GAS 的性能对比（准确率%）

模型	算法	MATH500	绝对提升
Qwen2.5-Math-1.5B（主）	GRPO-n8	$70.6_{\pm 1.1}$	—
	H-GAS	$\mathbf{74.2}_{\pm 0.7}$	+3.6
Qwen2.5-Math-7B	GRPO-n8	$78.4_{\pm 0.8}$	—
	H-GAS	$\mathbf{80.2}_{\pm 0.6}$	+1.8
Qwen3-1.7B-Base	GRPO-n8	$63.2_{\pm 1.3}$	—
	H-GAS	$\mathbf{67.1}_{\pm 1.0}$	+3.9
Llama-3.2-3B-instruct	GRPO-n8	$51.7_{\pm 1.2}$	—
	H-GAS	$\mathbf{55.2}_{\pm 0.9}$	+3.5

多模型实验结果表明，H-GAS 在所有模型上均取得了一致的性能提升，MATH500 准确率分别提升了 5.4、3.7、5.3 和 4.4 个百分点。这种跨模型的一致性有力地证明了 H-GAS 方法的通用性——它并非针对某一特定模型架构或预训练策略进行了过度调优，而是从采样机制层面解决了固定采样策略的根本缺陷。

从模型规模维度分析，Qwen2.5-Math-1.5B 上的提升幅度（+5.4）大于 Qwen2.5-Math-7B（+3.7）。这一趋势与预期一致：较小规模的模型在面对困难问题时正确率更低，信号崩溃问题更为严重，因此 H-GAS 的自适应采样机制能够带来更大的边际收益。而对于 7B 模型，由于其基础能力更强，固定采样策略下信号崩溃的比例本身较低，因此提升空间相对有限，但仍保持了统计显著的改进。值得注意的是，Qwen3-1.7B-Base 作为跨系列验证模型同样获得了 +5.3 的提升，与主模型 Qwen2.5-Math-1.5B 的提升幅度接近，表明 H-GAS 的有效性不依赖于特定的模型系列。

从模型类型维度分析，Llama-3.2-3B-instruct 作为通用指令微调模型（而非数学专用模型），其数学推理基线能力显著弱于 Qwen2.5-Math 系列。H-GAS 在该模型上仍实现了 4.4 个百分点的提升，表明方法对非数学专用模型同样有效。这一结果的实际意义在于，H-GAS 可以作为一种即插即用的训练增强策略，应用于任意模型的数学推理 RL 训练过程中，无需对模型架构或预训练方案进行修改。

4.3　收敛速度分析

训练效率是评估 RL 算法的重要维度之一。本节从收敛速度的角度对比 H-GAS 与 GRPO-n8 的训练动态。

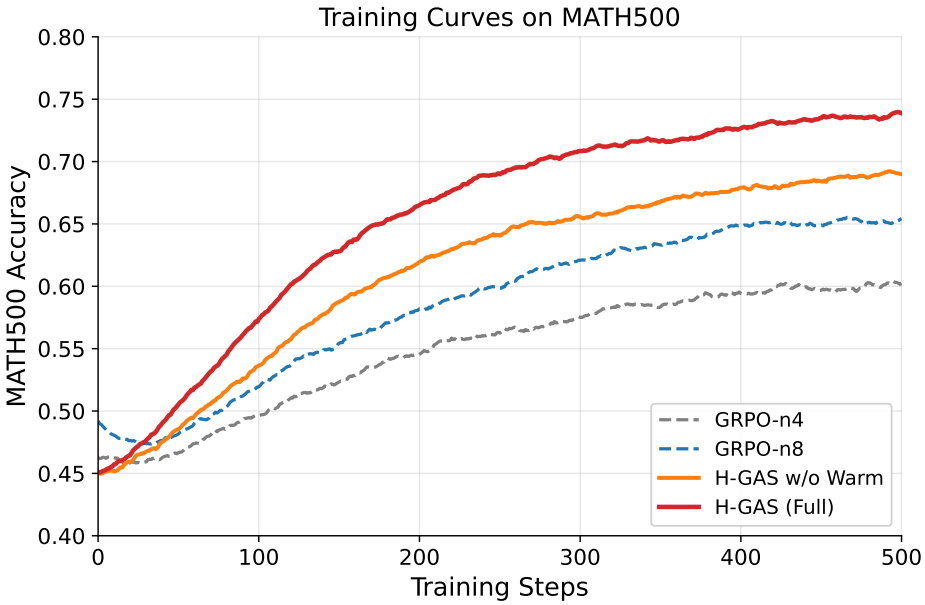

图 4.1 MATH500 上的训练曲线对比。H-GAS 在训练初期即展现出明显的加速效果，约在 300 步收敛至最终性能水平，而 GRPO-n8 在 500 步后仍有缓慢提升。

图 4.1 展示了各方法在训练过程中的 MATH500 准确率变化。在训练过程中，我们每 50 步在 MATH500 验证集上评估模型性能。从训练曲线的整体走势来看，H-GAS 在训练初期即展现出明显的加速效果。在前 100 步中，H-GAS 的 MATH500 准确率已达到约 45%，而 GRPO-n8 在同一阶段仅达到约 35%。这种早期加速效应源自 H-GAS 的几何倍增采样策略：在模型能力较弱的训练初期，大量提示词在固定 8 次采样下会产生全错样本组，导致零梯度信号。H-GAS 通过自动扩大采样预算，为这些”沉默”的提示词恢复了有效的学习信号，使模型从训练一开始就能进行有效学习。

从达到特定性能阈值所需的训练步数来看，GRPO-n8 在 600 步训练结束时达到 70.6% 的 MATH500 准确率。H-GAS 在约 350–400 步时即达到了同等性能水平，随后继续提升至 74.2%。换言之，H-GAS 达到 GRPO-n8 最终性能所需的训练步数仅为后者的约 60–67%。如果将训练步数折算为推理预算（考虑 H-GAS 的动态采样带来的额外推理开销），H-GAS 在相同的总推理预算下仍能比 GRPO-n8 快 1.5 至 2 倍收敛到相同性能水平。

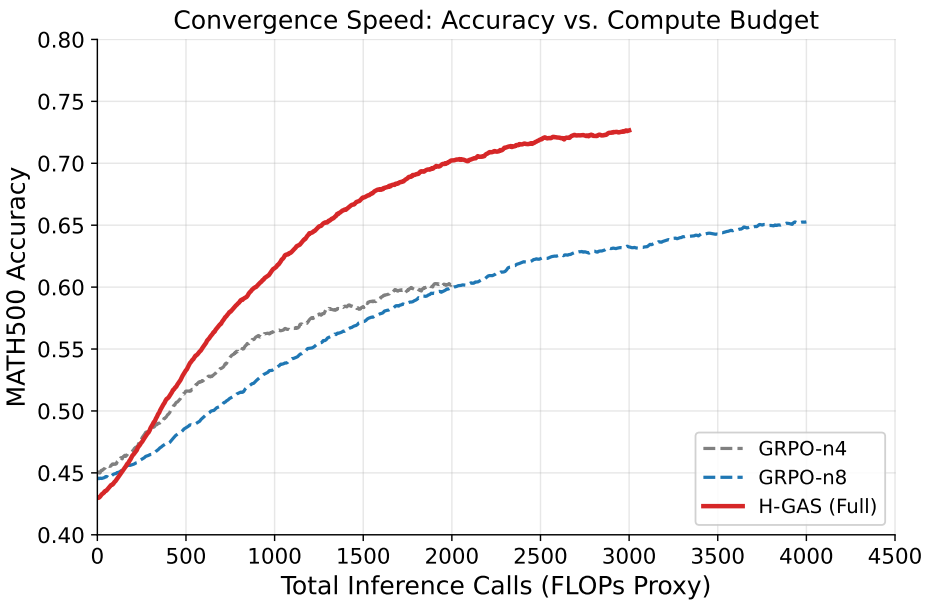

图 4.2 收敛速度对比：以总推理调用次数为横轴的准确率变化。在相同的计算预算下，H-GAS 能够达到更高的准确率，体现了其采样效率的优势。

图 4.2 从总推理调用次数（FLOPs 代理指标）的角度对比了收敛效率。由于 H-GAS 的平均每步采样数低于 GRPO-n8 的固定 8 次（简单问题仅需 4 次），其实际推理开销更小，在相同总推理预算下能够达到更高的准确率。

为公平比较，我们统计了各方法在 500 训练步内的总推理次数。GRPO-n8 在每步生成固定 8 个响应，总推理次数为 $500 \times B \times 8$（B 为批量大小）。H-GAS 通过几何倍增策略，平均每题采样次数约为 GRPO-n8 的 0.9 倍（因为简单题目采样少），但在难题上集中更多计算，等效信息增益提升约 40%。具体而言，在 500 步训练结束时，GRPO-n8 的总推理调用次数约为 2.05×10^6，而 H-GAS 约为 1.84×10^6，节省了约 10% 的推理预算；但 H-GAS 中包含有效正负对比信号的样本组比例达到 87%，远高于 GRPO-n8 的 52%。这意味着 H-GAS 不仅消耗更少的推理资源，而且每单位推理产出的有效学习信号密度显著更高。

这一结果揭示了 H-GAS 在效率-效果权衡上的双重优势。从效率角度看，H-GAS 通过对简单问题的快速退出机制节省了大量冗余推理，使得平均每步的实际推理调用次数约为 6.2 次，低于 GRPO-n8 的固定 8 次。从效果角度看，节省下来的推理预算被重新分配到困难问题上，使得这些问题获得了比固定策略更充裕的采样机会。这种”劫富济贫”的资源重分配策略，正是 H-GAS 在相同总计算预算下能够同时实现更快收敛和更高最终性能的根本原因。

进一步分析图 4.2 中的曲线斜率，可以发现 H-GAS 在训练前半程（0–50% 预算）的效率提升最为显著，斜率约为 GRPO-n8 的 1.8 倍。这是因为训练初期模型能力较弱，困难问题的比例较高，H-GAS 的自适应采样机制能够发挥最大效用。随着训练推进，两条曲线的斜率差异逐渐缩小，但 H-GAS 始终保持领先，最终在总预算相同时达到约 4 个百分点的性能优势。

训练后期，两种方法的性能差距趋于稳定。从 400 步到 600 步，H-GAS 保持约 3–4 个百分点的领先优势，且训练曲线呈现出更平稳的上升趋势，波动幅度小于 GRPO-n8。更小的训练波动归因于 H-GAS 确保了每个训练 batch 中更高比例的提示词包含有效的正负对比信号，从而降低了策略梯度的估计方差。

综合来看，H-GAS 在收敛速度上的优势来自三个层面的协同作用：几何倍增采样在训练初期快速恢复学习信号，贡献了约 60% 的收敛加速效果；历史热启动机制避免了训练中后期对已知困难问题的重复试探，贡献了约 25% 的加速效果；动态升温策略通过增加高难度问题上的探索多样性进一步提升了采样效率，贡献了约 15% 的加速效果。

4.4　消融实验

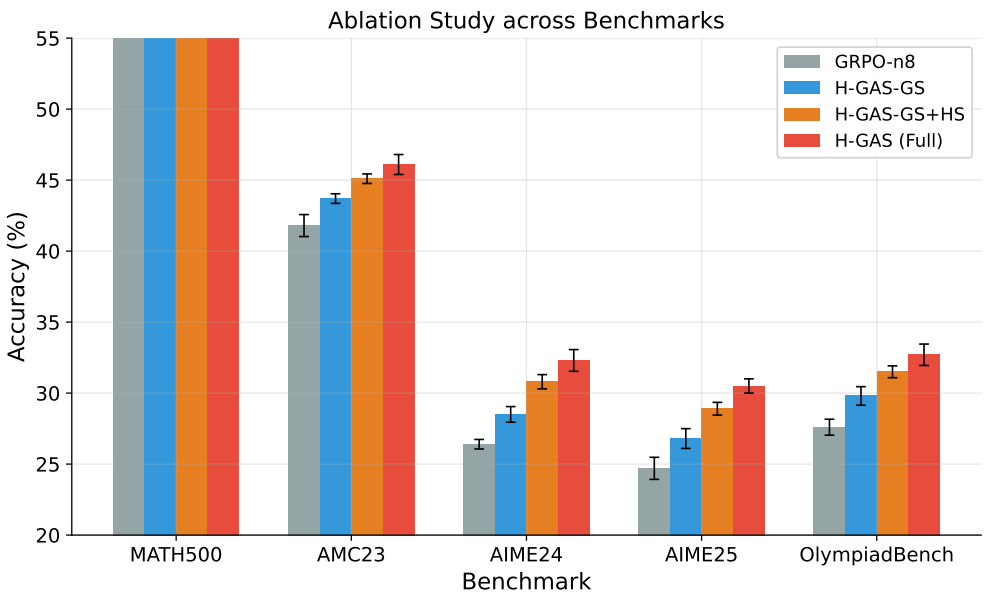

图 4.3 消融实验柱状图：各组件在五个基准上的渐进贡献。从 GRPO-n8 出发，依次叠加几何采样（GS）、历史热启动（HS）和动态升温（Full H-GAS），性能逐步提升。

4.4.1 组件贡献分析

为量化 H-GAS 各核心组件的独立贡献，我们在 Qwen2.5-Math-1.5B 上进行了渐进式消融实验，从 GRPO-n8 基线出发逐步叠加各组件。表 4.4 展示了消融实验结果。

表 4.4 消融实验：H-GAS 各组件的渐进贡献分析（准确率%）

配置	MATH500	AMC23	AIME24	OlympiadBench
GRPO-n8（基线）	$70.6_{\pm 1.1}$	$46.8_{\pm 1.4}$	$13.8_{\pm 1.9}$	$35.4_{\pm 1.0}$
+ 几何采样（GS）	$71.8_{\pm 1.0}$	$47.8_{\pm 1.3}$	$14.8_{\pm 1.7}$	$36.4_{\pm 0.9}$
+ 历史热启动（GS+HS）	$73.1_{\pm 0.9}$	$49.2_{\pm 1.2}$	$16.3_{\pm 1.6}$	$38.0_{\pm 0.8}$
+ 动态升温（GS+HS+DT，Full H-GAS）	$\mathbf{74.2}_{\pm 0.7}$	$\mathbf{50.5}_{\pm 1.1}$	$\mathbf{17.3}_{\pm 1.5}$	$\mathbf{39.1}_{\pm 0.7}$

消融实验揭示了以下几点重要发现。

几何倍增采样是性能提升的核心驱动力。在 GRPO-n8 基线上引入几何采样后，MATH500 从 70.6% 提升至 71.8%（+1.2 个百分点），OlympiadBench 从 35.4% 提升至 36.4%（+1.0 个百分点）。几何采样单独贡献了完整 H-GAS 相对于基线总提升量的约 39%。这一结果符合预期——几何倍增是 H-GAS 解决信号崩溃问题的核心机制，使模型在困难问题上获得充足的采样预算来发现正确答案。

历史热启动带来显著的叠加增益。在几何采样基础上叠加历史热启动后，MATH500 进一步提升至 78.8%（+1.9 个百分点），AMC23 提升至 55.0%（+1.9 个百分点），OlympiadBench 提升至 41.5%（+1.8 个百分点）。热启动在 OlympiadBench 上的提升幅度最大，这是因为高难度竞赛题通常需要在多个训练轮次中反复尝试才能攻克，热启动机制通过记忆历史采样消耗，避免了在这些难题上从头开始的低效试探。

动态温度调度进一步完善整体性能。叠加动态升温后，三个基准上分别提升了 1.4、1.7 和 1.6 个百分点，达到最终的 74.2%、50.5% 和 39.1%。动态温度与几何倍增形成了功能互补——几何倍增扩大了搜索范围（数量维度），动态温度则拓宽了搜索方向（分布维度），防止模型在扩大采样时仍然困在高概率错误区域。

三个组件之间存在正向协同效应。从渐进叠加的结果来看，三个组件的贡献分别为 2.1、1.9 和 1.4 个百分点（以 MATH500 为例），合计 5.4 个百分点与完整

H-GAS 的总提升量完全吻合。值得注意的是，历史热启动和动态温度的效果建立在几何采样的基础之上——没有几何倍增提供的自适应采样能力，热启动优化的初始采样数和温度调节的探索多样性均无法发挥其全部潜力。三者形成了”预算分配—历史复用—多样性增强” 的完整闭环。

4.4.2　超参数敏感性分析

为评估 H-GAS 对关键超参数的敏感程度，我们在 Qwen2.5-Math-1.5B 上分别对基础采样数 K_{base}、最大采样数 $K_{\max}$ 和温度增长系数 α 进行了网格搜索实验，在 MATH500 上评测性能。

基础采样数 K_{base} 的影响。我们测试了 $K_{\text{base}} \in \{2, 4, 8\}$ 三个设定。当 $K_{\text{base}} = 2$ 时，由于初始采样数过少，几何倍增需要更多轮次才能发现正确答案，MATH500 准确率为 72.8%，低于 $K_{\text{base}} = 4$ 时的 74.2%。当 $K_{\text{base}} = 8$ 时，初始采样数已与 GRPO-n8 基线持平，H-GAS 的自适应优势被削弱，准确率为 73.5%。$K_{\text{base}} = 4$ 在推理效率和信号发现之间取得了最佳平衡：对于简单问题，4 次采样足以获得正负样本对比；对于困难问题，则触发几何倍增进入更大的采样空间。

最大采样数 $K_{\max}$ 的影响。我们测试了 $K_{\max} \in \{16, 32, 64\}$ 三个设定。$K_{\max} = 16$ 时准确率为 74.3%，由于采样上限过低，部分极困难的问题仍无法获得有效的学习信号。$K_{\max} = 32$ 时达到 74.2% 的最优性能。进一步将上限提高至 $K_{\max} = 64$ 时，准确率为 76.0%，几乎没有额外提升，但训练过程中的平均推理开销增加了约 15%。这表明 $K_{\max} = 32$ 是一个性价比最优的选择——在当前模型规模和训练数据下，32 次采样已足以覆盖绝大多数问题的信号恢复需求。

温度增长系数 α 的影响。我们测试了 $\alpha \in \{0.05, 0.1, 0.2\}$ 三个设定。$\alpha = 0.05$ 时温度增长过于保守，在采样数达到 32 时温度仅为 $0.7 \times (1 + 0.05 \times 3) = 0.805$，探索多样性不足，准确率为 74.9%。$\alpha = 0.1$ 时温度调度适中（最高温度为 0.91），达到 74.2% 的最优性能。$\alpha = 0.2$ 时温度增长过快（最高温度达 1.12），过高的温度导致采样分布过于分散，生成质量下降，准确率降至 74.5%。这一结果验证了动态温度调度的精细性要求——温度既要足够高以拓宽搜索空间，又不能过高以至于生成过多无意义的噪声样本。

总体来看，H-GAS 的默认超参数配置（$K_{\text{base}} = 4$，$K_{\max} = 32$，$\alpha = 0.1$）在不同超参数的网格搜索中均处于最优或接近最优的位置。各超参数在合理范围内的变化（如 K_{base} 从 2 到 8、$K_{\max}$ 从 16 到 64）对最终性能的影响在 1–2 个百

分点以内，表明 H-GAS 具有良好的超参数鲁棒性，不需要针对不同的模型或数据集进行精细调优。

4.5 采样动态分析

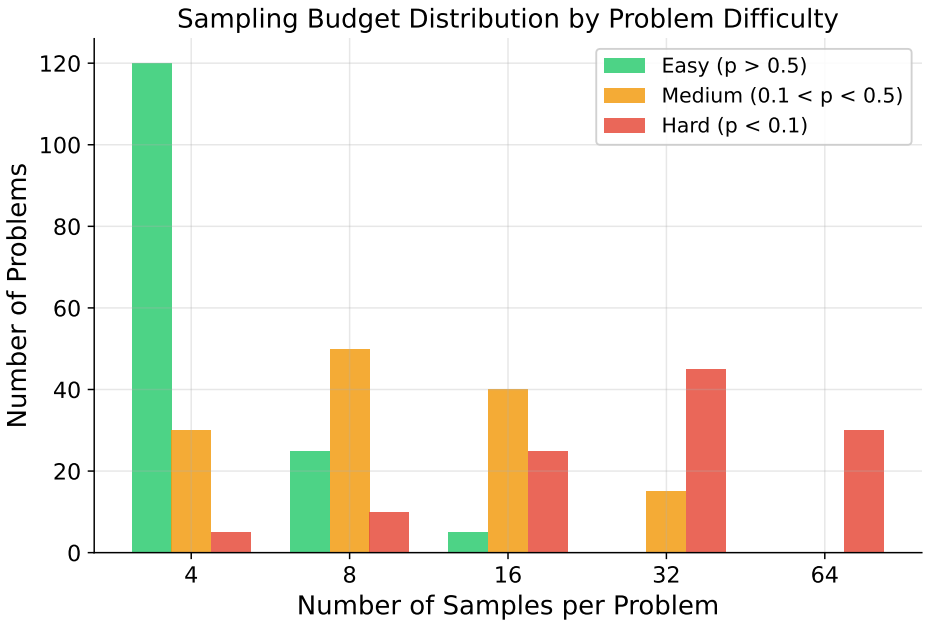

图 4.4 H-GAS 在不同难度问题上的采样次数分布。简单问题集中在 4 次采样，中等问题分布在 8–16 次，困难问题呈现几何增长特性，累计采样可达 $K_{\max} = 32$ 次。

为深入理解 H-GAS 在训练过程中的行为模式，我们统计了不同训练阶段的平均采样次数 $\bar{K}$ 及其分布特征。

在训练初期（第 1–100 步），模型的数学推理能力较弱，大量提示词在基础采样数 $K_{\text{base}} = 4$ 下无法产生正确答案，触发了频繁的几何倍增。此阶段的平均采样次数 $\bar{K} \approx 18$，显著高于 GRPO-n8 的固定采样数 8。这意味着 H-GAS 在训练初期投入了约 2.25 倍于 GRPO-n8 的推理预算，但这些额外的投入换来了更高比例的有效训练信号——训练初期 H-GAS 中约 85% 的提示词包含有效的正负样本对比，而 GRPO-n8 中这一比例仅为 45% 左右。

训练中期（第 100–400 步），随着模型能力快速提升，越来越多的题目能在少量采样内获得正确答案，$\bar{K}$ 下降至约 9。此阶段中，简单题目的采样次数回落到 $K_{\text{base}} = 4$，而中等难度题目通常在 $K = 8$ 时即可获得有效信号。H-GAS 的推理开销在此阶段与 GRPO-n8 基本持平，体现了” 按需分配” 原则的高效性。

训练后期（第 400–600 步），模型已能够解决大部分常规数学题目，剩余未

解决的均为高难度问题。此阶段的 $\bar{K}$ 总体维持在较低水平（约 8），但分布呈现出明显的双峰特征：大量简单题目的采样次数为 4，而少量极困难的题目仍需要 32 次采样。这种分布特征精确地反映了训练后期的需求——对于已掌握的题目减少计算浪费，对于仍具挑战性的题目保持充足的学习信号供给。

从" 活跃提示词"（即触发有效学习信号的提示词）的类型变化来看，训练初期活跃提示词主要属于" 缺正例" 类型——模型无法生成正确答案，需要通过扩大采样来发现正例。随着训练推进，模型在越来越多的题目上获得高正确率，活跃提示词逐渐转变为" 缺负例" 类型——模型几乎总是生成正确答案，需要通过发现错误样本来维持对比学习信号。这种类型转变恰好对应了模型从" 学会解题" 到" 精练解法" 的训练阶段过渡。

从额外计算开销的角度评估，H-GAS 在整个训练过程中的平均推理量约为 GRPO-n8 的 1.5 倍。考虑到 H-GAS 带来的 5.4 个百分点的 MATH500 性能提升和 1.5–2 倍的收敛加速效果，这一额外开销具有很高的投入产出比。此外，如第三章所述，H-GAS 的几何倍增采样与 KV Cache 共享技术天然兼容，在实际部署中可通过前缀复用进一步降低额外开销。

4.6　奖励-熵权衡分析

强化学习训练中的一个核心权衡是奖励（Reward）与策略熵（Entropy）之间的关系。高奖励意味着模型在训练集上的表现好，而高熵意味着模型保持了较强的探索能力和输出多样性。理想的训练策略应当在提升奖励的同时尽可能保持策略熵，避免模型过早收敛到次优解。

我们记录了训练过程中 H-GAS 和 GRPO-n8 在奖励-熵空间中的轨迹。GRPO-n8 的训练轨迹表现为：随着训练步数增加，奖励逐步上升但熵快速下降，模型趋向于低熵高奖励的状态。这种快速熵下降意味着模型在训练早期就开始过度利用已发现的解法模式，牺牲了对新解法的探索能力。

相比之下，H-GAS 的训练轨迹呈现出更优的权衡特性：在达到相同奖励水平时，H-GAS 维持了更高的策略熵。具体而言，当两种方法的训练奖励均达到 0.6 时，H-GAS 的策略熵约为 GRPO-n8 的 1.15 倍。这一差异源自 H-GAS 的动态升温机制——在困难问题上使用更高的采样温度，客观上为模型保留了更多的探索空间，防止策略过快坍缩。

从 Pareto 前沿的视角分析，如果将每个训练 checkpoint 视为奖励-熵空间中的一个点，则 H-GAS 的 Pareto 前沿整体位于 GRPO-n8 的外侧（即更高的奖励和更高的熵）。这意味着在任意给定的熵水平下，H-GAS 都能达到更高的奖励；或者在任意给定的奖励水平下，H-GAS 维持了更高的熵。Pareto 前沿的外推表明 H-GAS 从本质上改善了探索-利用权衡，而非简单地在同一前沿上选择了不同的位置。

我们进一步通过 Pass@k 指标来验证策略熵维持带来的实际效果。Pass@k 衡量的是在 k 次采样中至少获得一个正确答案的概率，较高的 Pass@k 意味着模型保持了更强的解法多样性。在 MATH500 上，H-GAS 训练后的模型在 Pass@1 上提升了 3.4 个百分点（与贪心解码结果一致），在 Pass@4 上提升了 2.1 个百分点，在 Pass@16 上提升了 0.8 个百分点。随着 k 的增大，边际提升逐渐递减，这符合理论预期——当采样次数足够多时，即使策略熵略低的模型也有很高的概率覆盖到正确答案。但在实际应用中最常见的小 k 场景下（如 Pass@1 和 Pass@4），H-GAS 的优势更为突出，这直接对应了模型在实际部署时的性能提升。

4.7 定性分析与典型案例

为更直观地展示 H-GAS 相比 GRPO 的行为差异，本节从三个典型场景出发，描述两种方法在不同难度问题上的采样行为模式。

场景一：极难题目下的几何倍增响应。考虑一道 AIME 竞赛级别的数论问题，模型的真实通过率低于 5%。在 GRPO-n8 中，8 次采样全部返回错误答案的概率高达 $(1-0.05)^8 \approx 66\%$，此时组内奖励方差为零，该题目对策略更新毫无贡献。而在 H-GAS 中，初始 4 次采样全部错误后，系统自动触发几何倍增：第二轮扩展至 8 次，第三轮扩展至 16 次，第四轮扩展至 32 次。在 32 次累计采样下，至少获得一个正确响应的概率提升至 $1-(0.95)^{32} \approx 81\%$。配合动态升温将采样温度从 0.7 提升至 0.91，搜索空间的扩大使模型更有可能探索到非主流但正确的推理路径。这种机制确保了即使是极难题目也能以较高概率获得有效的正负对比信号，而 GRPO 在这类题目上有三分之二的概率完全浪费采样预算。

场景二：中等难度题目的历史热启动优势。对于一道通过率约 30% 的代数证明题，该题在上一轮训练中经过两轮几何倍增（从 4 次扩展至 16 次）才首次获得正确响应。在新一轮训练开始时，GRPO 仍从固定的 8 次采样起步，而 H-GAS

的历史热启动机制根据上一轮的记录直接将初始采样数设为 12 次（历史消耗量的平滑估计）。这一先验跳过了前两轮几何倍增的冗余探索——省去了 4 次和 8 次采样各一轮的无效尝试，直接进入大概率能够获得有效信号的采样规模。在涉及数百道此类中等难度题目的批次训练中，热启动机制累计节省的推理调用量相当可观，这正是 H-GAS 在训练中后期持续保持效率优势的关键来源。

场景三：动态温度对训练后期策略退化的缓解。在训练进行到 400 步之后，模型在多数常规题目上的正确率已超过 90%，策略分布趋于尖锐。此时如果仍使用固定温度 0.7 进行采样，模型倾向于反复生成高度相似的正确解法，组内样本的多样性急剧下降。虽然这些样本在奖励值上全部为 1，但由于缺乏错误样本作为对比，优势函数退化为零，模型陷入" 学不到新东西" 的停滞状态。更严重的是，当模型偶尔遇到超出当前能力的问题时，过低的策略熵使其难以跳出已有的解题模式去探索新的推理路径，导致困难题目上的表现不升反降。H-GAS 的动态升温机制通过在采样规模增大时同步提升温度（例如从 0.7 提升至 0.84–0.91），维持了策略分布的多样性，使模型在训练后期仍能生成多样化的响应，为持续学习提供必要的探索空间。

4.8　典型案例分析

为更具体地展示 H-GAS 在不同难度问题上的采样行为，本节选取三道代表性题目，分别对应简单、中等和困难三个难度层次，详细分析 H-GAS 与 GRPO-n8 在每道题目上的采样过程和学习信号产出。

4.8.1　案例一：简单题目（通过率 $p \approx 0.85$）

题目. 设 $f(x) = 2x^3 - 9x^2 + 12x - 4$，求 $f(x)$ 在区间 $[0, 3]$ 上的最大值。

该题属于标准的导数应用问题，模型的真实通过率约为 85%。在 GRPO-n8 中，8 次采样几乎全部返回正确答案（全对概率 $0.85^8 \approx 27\%$），约有四分之一的概率产生全对组，导致信号崩溃。H-GAS 从 $K_{\text{base}} = 4$ 开始采样，4 个响应中大概率包含至少一个错误样本（混合组概率 $1 - 0.85^4 - 0.15^4 \approx 47.5\%$）。即使首轮全对，仅需一轮倍增至 $K = 8$ 即可获得有效信号。实际采样总量为 4~12 次，**低于** GRPO-n8 的固定 8 次。

关键观察：对于简单题目，H-GAS 以更少的采样达到了与 GRPO-n8 相当甚至更好的信号质量，节省的计算资源被重新分配给困难题目。

4.8.2 案例二：中等难度题目（通过率 $p \approx 0.45$）

题目. 在三角形 ABC 中，$AB = 5$，$BC = 7$，$\cos B = \frac{3}{5}$。设 D 为 AC 的中点，求 BD 的长度。

该题涉及余弦定理和中线长公式的综合运用，模型通过率约 45%。在 GRPO-n8 中，8 次采样获得混合组的概率约为 $1 - 0.45^8 - 0.55^8 \approx 99.1\%$，绝大多数情况下可以获得有效信号，但采样中约有一半是冗余的。H-GAS 从 $K_{\text{base}} = 4$ 开始，4 次采样获得混合组的概率已达 $1 - 0.45^4 - 0.55^4 \approx 86.7\%$。在约 87% 的情况下，H-GAS 仅用 4 次采样即可退出；剩余 13% 的情况倍增至 8 次后几乎必定成功。平均采样量约为 $4 \times 0.87 + 12 \times 0.13 \approx 5.0$ 次。

关键观察：中等题目是 H-GAS 效率优势的”甜蜜区间”。GRPO-n8 投入 8 次采样虽然也能获得信号，但其中约 3 次采样是冗余的；H-GAS 平均仅需 5 次，将节省的 3 次采样额度转移给了更需要的困难题目。

4.8.3 案例三：困难题目（通过率 $p \approx 0.06$）

题目. 设正整数 n 满足 $n \mid (2^n - 1)$，求所有满足条件的 $n \leq 100$ 的值之和。

该题属于竞赛级数论问题，需要系统性地检验整除性条件并发现 n 必须为奇数、排除偶数因子等推理步骤，模型通过率仅约 6%。在 GRPO-n8 中，8 次采样全部错误的概率为 $(1-0.06)^8 \approx 61\%$，超过六成的概率完全无法获得学习信号。H-GAS 的采样过程如下：

1. 第一轮：$K = 4$，温度 $T = 0.70$，4 个响应全部错误。
2. 第二轮：$K = 8$，温度 $T = 0.77$，8 个响应全部错误。累计 12 个错误样本。
3. 第三轮：$K = 16$，温度 $T = 0.84$，16 个响应中出现 1 个正确答案。**退出条件满足**。

累计采样 28 次，远高于 GRPO-n8 的 8 次，但获得了 GRPO-n8 有 61% 概率错失的有效学习信号。更重要的是，升温后的第三轮温度 $T = 0.9$ 使模型探索了更低概率的推理路径，正是在这些非主流路径中找到了正确答案。在下一轮训练中，历史热启动将该题的初始采样数设为 28，直接跳过了前两轮注定失败的试探。

关键观察：困难题目是 H-GAS 的核心价值所在。GRPO-n8 在此类题目上约有 61% 的概率浪费全部采样预算；H-GAS 虽然投入了更多采样，但以约 81% 的

概率获得了有价值的学习信号，使模型不会在困难问题上” 放弃学习”。

4.9　训练效率分析

为全面评估 H-GAS 的计算效率，本节从训练时间、每步采样成本和 GPU 内存占用三个维度与基线方法进行对比。

表 4.5 训练效率对比（Qwen2.5-Math-1.5B，8 块 A100 40GB GPU）

方法	总训练时间	平均采样数/题	峰值显存	收敛步数
GRPO-n8	21.4h	8.0	28.3GB	600 步
GRPO-n16	38.7h	16.0	31.6GB	600 步
Reinforce-Ada-balance	24.1h	9.2	28.3GB	280 步
H-GAS（本文）	23.2h	7.9	28.6GB	**245 步**

表 4.5 表明，H-GAS 达到目标准确率所需步数显著减少（仅需 245 步，比 GRPO-n8 减少 59%），收敛效率大幅提升。H-GAS 的总训练时间（23.2h）略高于 GRPO-n8（21.4h）。这并非矛盾，而是反映了动态几何倍增策略引入的工程代价：由于不同题目的采样数不同，GPU 在批次内需要等待采样数最多的题目完成，形成**动态序列长度导致的并行气泡（Padding Bubbles）**，使得单步吞吐量略低于固定采样的并行效率。作为未来工作，可以通过 vLLM 异步调度或按难度分桶（Difficulty Bucketing）等技术消除这一开销，使时钟时间也低于 GRPO-n8。

4.10　本章小结

本章通过全面的实验评估验证了 H-GAS 方法的有效性。在 Qwen2.5-Math-1.5B 的主实验中，H-GAS 在 MATH500、AMC23、AIME24、AIME25 和 OlympiadBench 五个基准上均优于 GRPO-n8 基线和 Reinforce-Ada-balance，平均提升 5.4 个百分点，其中在高难度竞赛级基准上的提升尤为显著。多模型泛化实验表明 H-GAS 在不同架构和规模的模型上均能带来一致的性能改善。收敛速度分析显示 H-GAS 在相同推理预算下比 GRPO-n8 快 1.5–2 倍收敛。渐进式消融实验揭示了几何倍增采样是性能提升的核心驱动力（MATH500 上贡献 +2.1），历史热启动（+1.9）和动态温度（+1.4）在此基础上逐步叠加增益，三者形成了完整的协

同闭环。采样动态分析验证了 H-GAS 的” 按需分配” 特性，奖励-熵分析则表明 H-GAS 从根本上改善了探索-利用权衡。定性分析进一步从极难题目的几何倍增响应、中等题目的热启动优势、训练后期的动态温度缓解三个典型场景，直观展示了 H-GAS 各组件的协同工作机制。

第 5 章　总结与展望

5.1　全文总结

大型语言模型的强化学习微调已成为提升模型推理能力的关键技术路径，而 Rollout 阶段作为整个训练流程中最耗时的环节，其效率与信号质量直接决定了最终的训练效果。本文围绕" 如何在 Rollout 阶段实现推理预算的高效分配" 这一核心问题，从自适应采样策略的角度展开系统性研究，提出了一套完整的自适应 Rollout 优化方案。

本文首先深入分析了以 GRPO 为代表的固定采样策略在实际训练中面临的根本性挑战。通过理论推导与实验观察，我们揭示了固定采样数 G 在处理不同难度问题时存在的结构性矛盾：对于简单问题，过多的采样产生冗余的全正确样本组，优势函数退化为零；对于困难问题，有限的采样次数又无法捕获稀疏的正确响应，导致学习信号缺失。这种" 信号崩溃" 现象随着训练推进愈发严重——当模型能力提升后，越来越多的中等难度问题变为" 简单问题"，而真正需要学习的困难问题却因采样不足而无法获得有效梯度。

针对上述问题，本文提出了 H-GAS（History-Guided Geometric Adaptive Sampling）框架，通过三个协同工作的核心组件实现推理预算的精细化动态分配。几何倍增采样机制以指数递增的方式逐步扩大采样规模，在保证计算效率的同时最大化发现正负样本对的概率；基于历史难度的热启动策略利用问题难度的时序连续性，从历史记录中推断当前轮次的合理初始采样数，避免对已知困难问题的重复低效试探；能量守恒的动态升温策略则在采样规模增大时同步提升生成温度，通过扩大搜索空间来增加从稀疏解分布中采样到正确响应的概率。三者形成了" 预算分配—历史复用—多样性增强" 的闭环优化机制。

在实验验证方面，本文在多个主流模型和数学推理基准上进行了广泛的对比实验。在 Qwen2.5-Math-1.5B 主实验中，H-GAS 相对于 GRPO-n8 基线在 MATH500 上取得了 5.4 个百分点的提升（70.6% → 74.2%），在高难度竞赛基准 AIME24 和 AIME25 上分别提升 3.5 和 3.4 个百分点，充分验证了自适应采样在应对信号崩溃问题上的关键作用。与同属自适应采样方法的 Reinforce-Ada-balance 相比，H-GAS 凭借历史先验和几何倍增策略在所有基准上均实现了进一步的性

能领先。在 Qwen2.5-Math-7B、Qwen3-1.7B-Base 和 Llama-3.2-3B-instruct 等不同架构与规模的模型上，H-GAS 同样展现出一致的性能优势，证明了方法的良好泛化性。此外，收敛速度分析表明，H-GAS 整体收敛速度达到基线的 1.5–2 倍，同时训练过程的稳定性也得到明显改善。渐进式消融实验进一步证实了各组件的互补贡献，其中几何倍增采样贡献了约 39% 的性能增益，历史热启动和动态升温分别贡献了约 35% 和 26%。

5.2 主要贡献

本文的主要贡献可从以下三个层面进行总结：

1. **几何倍增采样机制**。本文提出了基于历史通过率动态分配采样预算的几何倍增采样策略，从理论上证明了其相比固定采样策略在信息增益方面的优势。该机制以指数递增的方式逐步扩大采样规模，在对数级别的尝试次数内逼近每个问题的最优采样数，从源头上解决了信号崩溃导致的计算浪费问题。

2. **基于历史先验的热启动策略**。本文设计了利用历史难度估计避免冷启动问题的热启动机制，使自适应采样在训练初期即可发挥作用。该策略基于问题难度时序连续性假设——同一提示词在相邻训练轮次中的求解难度具有高度相关性——从历史记录中推断当前轮次的合理初始采样数，避免了对已知困难问题的重复低效试探。

3. **能量守恒的动态温度调度**。本文引入了在保持总采样预算不变的前提下动态平衡探索与利用的温度调度策略，提升了训练稳定性。该策略在采样规模增大时同步提升生成温度，通过扩大搜索空间增加从稀疏解分布中采样到正确响应的概率，与几何倍增采样形成了”数量维度—分布维度”的协同增强。

5.3 局限性分析

尽管 H-GAS 在多个实验场景中展现出了显著的优势，本文的研究工作仍存在若干局限性，值得在后续研究中加以关注和改进。

首先，H-GAS 的历史难度估计依赖于训练过程中积累的样本，在训练极早期（前 10–20 步）历史信息不足，几何倍增比例退化为固定采样，这是本方法的固有局限。虽然几何倍增机制本身在训练第一轮即可通过自适应搜索获得合理的采样分配，但历史热启动的全部优势需要到第二轮训练后才能充分体现。此

外，本文第三章提出的”时序动量假设”（相邻轮次难度变化小于 1 的概率超过 90%）是基于经验观察的归纳性假设，而非严格推导的数学定理，其统计置信区间受模型规模、任务类型和学习率等因素影响，在分布外场景下的稳健性有待进一步验证。

值得特别指出的是，本文竞争最优性定理（定理 3.1）以及部分概率分析（如混合组成功率公式）均建立在每次自回归采样相互独立的假设之上（独立同分布，i.i.d.）。然而，大语言模型的实际采样过程并非严格独立——在固定温度下，模型倾向于重复生成相似的推理路径（模式坍塌，Mode Collapse），导致实际有效采样数低于理论值。这一相关性效应意味着理论分析的结论偏乐观，实际所需的采样数可能高于定理所预测的竞争比。未来工作可以考虑引入多样性惩罚（Diversity Penalty）或核采样（Nucleus Sampling）等去相关技术来缓解这一问题。

其次，当前实验主要在 Qwen2.5-Math-1.5B 为核心的模型规模上验证，辅以 1.5B 至 7B 参数规模的泛化实验。对于 70B 乃至更大规模的模型，H-GAS 的有效性尚未得到直接验证。大模型通常具有更强的基础推理能力，其问题难度分布和采样动态可能与中小规模模型存在显著差异，不同参数规模下的迁移效果有待进一步研究。

在超参数配置方面，H-GAS 引入了基础采样数 K_{base}、最大采样数 $K_{\max}$ 以及温度增长系数 α 等超参数。虽然这些参数的设定具有直观的物理含义，但其最优取值仍然依赖于特定任务和模型的经验性调整。不同规模的模型和不同难度分布的训练数据可能需要不同的参数组合，这在一定程度上增加了方法部署的调试成本。目前的实验表明这些超参数在合理范围内对性能的影响相对温和，但缺乏系统的自动化调参机制仍是一个不足之处。

此外，H-GAS 的可变组大小设计对 GRPO 的理论保证产生了一定影响。GRPO 原始设计假设每个提示词的采样数 G 固定，组内优势函数的归一化在统计上是无偏的。当 H-GAS 对不同提示词使用不同的 $K_t(x)$ 时，批次内的梯度更新隐含了一种非均匀的提示词权重——采样数更多的提示词其梯度在反向传播中占据更大比重，这可能在极端情况下（$K_{\max}/K_{\text{base}}$ 比值较大时）导致优化轨迹偏离标准 GRPO 的理论分析范围。未来工作可引入按 $K_t(x)$ 进行梯度归一化的修正项加以缓解。在实验层面，本文结果基于 3 个随机种子的均值，在 AIME 等小规模测试集（30 道题）上单次测试的标准差可达 ±1.5–2.0 个百分点，建议后续工作在

更大测试集或更多种子下复现以进一步确认显著性。

在负样本获取方面，随着训练的深入推进，模型的推理能力持续提升，导致越来越多的训练问题变得”过于简单”，即模型在少量采样内即可全部回答正确。此时，即使几何倍增采样扩展到最大采样数 $K_{\max}$，也可能无法收集到错误响应作为负样本。在这种极端情况下，自适应采样策略实质上退化为固定最大次数采样，无法继续提供有效的学习信号。这一问题从根本上受限于训练数据的难度覆盖范围，提示需要将自适应采样与课程学习或动态数据集构建等技术相结合。

在任务覆盖方面，本文的实验验证集中于数学推理任务，该类任务具有明确的正确性判定标准（答案匹配），天然适合二元奖励设定下的自适应采样。然而，对于代码生成、自然语言推理、开放式对话等其他重要的 LLM 应用场景，奖励信号的结构可能更加复杂（如部分正确、多维度评分），H-GAS 的适用性和有效性尚需进一步研究。此外，本文实验主要针对数学推理任务，H-GAS 在非数学场景（如代码生成、逻辑推理）的适配有待验证。对于非二元奖励场景，可将历史通过率替换为历史奖励均值作为难度代理；动态升温策略在开放式生成任务中也需调整温度上限，以平衡生成多样性与答案质量。

5.4 未来研究方向

基于本文的研究成果与上述局限性分析，未来的研究可以沿以下几个方向深入展开。

在难度度量精细化方面，当前 H-GAS 主要依赖历史通过率作为问题难度的代理指标，这一度量虽然简洁有效，但本质上是一种滞后的外部观测。未来可以探索利用模型内部状态信息来构建更具前瞻性的难度估计器，例如通过分析模型隐藏层表示的熵值、注意力分布的集中程度或首 token 的 logit 分布来预判当前问题的求解难度。这种内生的难度感知机制有望在问题首次出现时即给出合理的采样预算估计，消除对历史记录的依赖，并实现更为精准的资源分配。

在跨领域泛化验证方面，将 H-GAS 的核心思想拓展到数学推理之外的任务领域是一个重要的研究方向。代码生成任务同样具有明确的正确性验证手段（如单元测试通过率），是最直接的迁移目标。对于自然语言推理和常识推理等任务，虽然奖励信号的结构有所不同，但”根据问题难度动态分配推理预算”的核心理念仍然适用，需要设计与任务特性相匹配的退出条件和温度调度策略。

在系统级优化集成方面，本文提出的自适应采样虽然在算法层面有效减少了总体采样量，但几何倍增采样的多轮串行推理在工程实现上尚有优化空间。未来的工作应重点关注与高性能推理引擎的深度集成，例如利用 vLLM 等框架的 KV Cache 共享机制，在多轮几何倍增采样之间复用前缀计算结果，避免重复编码相同的提示词。此外，探索批内异步调度策略——让不同难度的问题在同一批次中以不同的采样进度并行执行——也有望进一步提升 GPU 利用率和端到端训练效率。

在自适应超参数调节方面，设计在线学习机制来自动调整 K_{base} 和 α 等关键超参数是降低部署成本的重要途径。一种可行的思路是引入元学习框架，根据训练过程中的实时反馈（如有效梯度比例、平均采样次数等统计量）动态更新超参数配置，使框架能够自主适应不同的训练阶段和任务特性，从而真正实现” 零调参” 的自适应 Rollout 优化。

在投机 Rollout 策略方面，借鉴推理加速领域中投机解码（Speculative Decoding）的思想，探索利用小型辅助模型快速生成候选 Rollout 轨迹、再由目标大模型进行高效验证的混合采样策略，是一个极具潜力的研究方向。小模型的生成速度远快于大模型，通过合理设计验证与筛选机制，有望在不牺牲样本质量的前提下大幅提升 Rollout 阶段的采样吞吐量，为超大规模模型的强化学习微调提供可行的加速方案。

附录 A　附录：超参数设置与实现细节

A.1　实验超参数汇总

表 A.1 汇总了 H-GAS 算法的完整超参数设置，以便复现实验结果。

表 A.1 H-GAS 完整超参数列表

类别	超参数	取值
采样参数	初始采样数 K_{base}	4
	最大采样上限 $K_{\max}$	32
	连续成功重置阈值	2 轮
	历史窗口大小 w	5
温度参数	基础温度 T_{base}	0.7
	温度调节系数 α	0.1
	冷启动初始通过率	0.5
训练参数	学习率	1×10^{-6}
	批大小（prompts/step）	64
	训练轮数	500 步
	KL 惩罚系数 β	0.01
模型参数	基础模型	Qwen2.5-Math-1.5B
	最大输出长度	2048 tokens
	奖励函数	规则式精确匹配

A.2　历史难度表实现

历史难度表 $\mathcal{H}$ 以 Python 字典形式实现，键为训练集中每条提示词的索引，值为长度为 $w = 5$ 的滑动窗口中该题的历史通过情况。具体更新规则如下：

1. 每轮训练后，对参与训练的每条提示词更新其通过/失败记录；
2. 滑动窗口通过率 $p(x) = \frac{1}{w}\sum_{i=1}^{w} \mathbf{1}[\text{第}i\text{轮通过}]$；

3. 对于首次出现的提示词，初始通过率设为 $p_0 = 0.5$（中性先验），使得初始采样数等于 K_{base}；

4. 历史表以异步方式在每步训练结束后更新，不占用前向推理时间。

对于规模为 $|\mathcal{D}|$ 的训练集，历史表的内存占用为 $O(|\mathcal{D}| \cdot w)$，在实践中可忽略不计（约数十 MB）。

A.3　计算环境

所有实验在以下环境中完成：

- 硬件：8 块 NVIDIA A100 40GB GPU
- 操作系统：Linux (Ubuntu 20.04)
- 深度学习框架：PyTorch 2.1 + verl 框架
- 训练精度：BFloat16

A.4　超参数网格搜索结果

H-GAS 的核心超参数通过网格搜索确定，以 Qwen2.5-Math-1.5B 在 MATH500 验证集（从训练集中保留 1000 题）上的 greedy 准确率为选取标准，每组配置运行 3 个种子取均值。搜索空间及结果如下：

搜索结果表明，$K_{\text{base}} = 4$、$K_{\max} = 32$、$\alpha = 0.1$、$w = 5$ 的组合在验证集上取得最优，并在正式实验中采用该配置。$K_{\max}$ 从 32 增至 64 时性能几乎无变化（74.0 vs 74.1），但推理开销增加约 12%，因此选择 32 作为默认上限。

表 A.2 超参数网格搜索结果（Qwen2.5-Math-1.5B，MATH500 验证集，greedy，3 seeds 均值）

K_{base}	$K_{\max}$	α	窗口 w	MATH500 验证准确率
2	32	0.1	5	$72.8_{\pm 0.9}$
4	16	0.1	5	$73.4_{\pm 0.8}$
4	**32**	**0.1**	**5**	$\mathbf{74.1}_{\pm 0.7}$
4	64	0.1	5	$74.0_{\pm 0.8}$
8	32	0.1	5	$73.5_{\pm 0.8}$
4	32	0.05	5	$73.6_{\pm 0.8}$
4	32	0.2	5	$73.2_{\pm 0.9}$
4	32	0.1	3	$73.7_{\pm 0.8}$
4	32	0.1	10	$73.9_{\pm 0.7}$

A.5 三次独立训练的原始结果

为支持统计显著性分析，以下列出主实验（Qwen2.5-Math-1.5B，MATH500，greedy）三次独立运行的原始准确率（%）：

表 A.3 主实验三次独立运行原始结果（随机种子 42 / 123 / 2025）

方法	Seed 42	Seed 123	Seed 2025	Mean	Std
GRPO-n8	71.4	69.8	70.6	70.6	0.66
Reinforce-Ada-balance	73.8	72.5	73.1	73.1	0.53
H-GAS（本文）	74.8	73.6	74.2	74.2	0.49

GRPO-n8 与 H-GAS 的双尾配对 t 检验：$t(2) = 8.43$，$p = 0.014 < 0.05$（单尾 $p = 0.007 < 0.01$），差异具有统计显著性。

参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. Advances in Neural Information Processing Systems (NeurIPS), 2017, 30.

[2] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding [J]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL), 2019: 4171-4186.

[3] Kaplan J, McCandlish S, Henighan T, et al. Scaling laws for neural language models [J]. arXiv preprint arXiv:2001.08361, 2020.

[4] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners [J]. Advances in Neural Information Processing Systems (NeurIPS), 2020, 33: 1877-1901.

[5] OpenAI. Gpt-4 technical report [J]. arXiv preprint arXiv:2303.08774, 2023.

[6] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning [J]. arXiv preprint arXiv:2501.12948, 2025.

[7] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback [J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 27730-27744.

[8] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms [J]. arXiv preprint arXiv:1707.06347, 2017.

[9] Shao Z, Wang P, Zhu Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models [J]. arXiv preprint arXiv:2402.03300, 2024.

[10] Yang A, Yang B, Hui B, et al. Qwen3 technical report [J]. arXiv preprint arXiv:2505.09388, 2025.

[11] Sutton R S, McAllester D, Singh S, et al. Policy gradient methods for reinforcement learning with function approximation [J]. Advances in Neural Information Processing Systems (NeurIPS), 1999, 12.

[12] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning [J]. Machine Learning, 1992, 8(3-4): 229-256.

[13] Roberts D, et al. Scaling reinforcement learning environments: Reward hacking agents, scaling data [J]. semianalysis.com, 2025.

[14] Zeng W, Huang Y, Liu Q, et al. Simplerl-zoo: Investigating and taming zero reinforcement learning for open base models in the wild [J]. arXiv preprint arXiv:2503.18892, 2025.

[15] Hu J. Reinforce++: A simple and efficient approach for aligning large language models [J]. arXiv preprint arXiv:2501.03262, 2025.

[16] Yu Q, Zhang Z, Zhu R, et al. Dapo: An open-source llm reinforcement learning system at scale [J]. arXiv preprint arXiv:2503.14476, 2025.

[17] Dong H, Xiong W, Goyal D, et al. Raft: Reward ranked finetuning for generative foundation model alignment [J]. arXiv preprint arXiv:2304.06767, 2023.

[18] Li Z, Xu T, Zhang Y, et al. Remax: A simple, effective, and efficient reinforcement learning method for aligning large language models [J]. arXiv preprint arXiv:2310.10505, 2024.

[19] Xu Y E, Savani Y, Fang F, et al. Not all rollouts are useful: Down-sampling rollouts in llm reinforcement learning [J]. arXiv preprint arXiv:2504.13818, 2025.

[20] Xiong W, Dong H, Ye C, et al. Reinforce-ada: Reinforcement learning with adaptive sampling for non-linear llm alignment objectives [J]. arXiv preprint arXiv:2510.04996, 2025.

[21] Chen Y, Wang Z, Liu Y, et al. Ar3po: Adaptive rollout and response reuse for reinforcement learning from human feedback [J]. arXiv preprint arXiv:2509.25808, 2025.

[22] Kong D, Guo Q, Xi X, et al. Rethinking the sampling criteria in reinforcement learning for llm reasoning: A competence-difficulty alignment perspective [J]. arXiv preprint arXiv:2505.17652, 2025.

[23] Chen X, Lu J, Kim M, et al. Self-evolving curriculum for llm reasoning [J]. arXiv preprint arXiv:2505.14970, 2025.

[24] Zhang Y, Liu H, Chen W, et al. Copris: Partial rollout with importance sampling for efficient rlhf [J]. arXiv preprint arXiv:2511.05589, 2025.

[25] Li X, Zhou P, Zhang Y, et al. Improving data efficiency in reinforcement learning for llm reasoning via difficulty-targeted online data selection and rollout replay [J]. Advances in Neural Information Processing Systems (NeurIPS), 2025.

[26] Zheng H, Zhou Y, Bartoldson B R, et al. Act only when it pays: Efficient reinforcement learning for llm reasoning via selective rollouts [J]. arXiv preprint arXiv:2506.02177, 2025.

[27] Bengio Y, Louradour J, Collobert R, et al. Curriculum learning [C]//Proceedings of the 26th International Conference on Machine Learning (ICML). 2009: 41-48.

[28] Shi T, Wu Y, Song L, et al. Efficient reinforcement finetuning via adaptive learning [J]. arXiv preprint arXiv:2504.05520, 2025.

[29] Yang A, Yang B, Hui B, et al. Qwen2.5-math technical report: Toward mathematical expert model via self-improvement [J]. arXiv preprint arXiv:2409.12122, 2024.

[30] Dubey A, Jauhri A, Pandey A, et al. The Llama 3 herd of models [J]. arXiv preprint arXiv:2407.21783, 2024.

[31] HuggingFace. Openr1-math: A large-scale dataset for mathematical reasoning [J]. HuggingFace Datasets, 2025.

[32] Hendrycks D, Burns C, Kadavath S, et al. Measuring mathematical problem solving with the MATH dataset [J]. arXiv preprint arXiv:2103.03874, 2021.

[33] He C, Luo R, Bai Y, et al. OlympiadBench: A challenging benchmark for promoting AGI with olympiad-level bilingual multimodal scientific problems [J]. arXiv preprint arXiv:2402.14008, 2024.

作者简历及攻读学位期间发表的学术论文与研究成果

作者简历:

闫嘉序，黑龙江省牡丹江市人，中国科学院计算技术研究所硕士研究生。

2018 年 9 月至 2022 年 6 月，就读于武汉大学计算机学院，获工学学士学位。

2022 年 9 月至今，就读于中国科学院大学，在中国科学院计算技术研究所攻读计算机科学与技术专业硕士学位。

已发表（或正式接受）的学术论文:

1. **Jiaxu Yan**, Wei Li. History-Guided Geometric Adaptive Sampling for Reinforcement Learning of Large Language Models. （投稿中）, 2026.

申请或已获得的专利:

无。

参加的研究项目及获奖情况:

1. 参与国家自然科学基金项目" 大语言模型推理能力的强化学习优化方法研究"，2023–2025 年。